

Relatório

Projeto LLM Tagging

Patrícia Pereira Bertoli e Carlos Henrique Kauffmann

21/09/2026

Diferentemente de analisar uma variável específica, fizemos um experimento que busca verificar como modelos de LLM diferentes se comportam na realização de uma mesma tarefa de etiquetagem.

Nossos procedimentos foram:

1. Selecionamos o arquivo 00000209_16.txt, composto de um texto de autoria de Henry James com 961 palavras (4.577 caracteres sem espaço ou 5.446 caracteres com espaço)
2. Fizemos o upload do arquivo e do tagset simultaneamente em dois “Mac Air” diferentes, sendo (1) um com a versão chatGPT 5.5 gratuita e (2) outro com a versão 5.6 think paga.

Demos o seguinte prompt:

“You are a Corpus Linguist annotating texts for Part of Speech. For this task, you are being provided with a tagset and a text to tag as attachments. Tag the following text using this tagset. Enter each tag between {} after each case. Eg. A {1} casa {902, 23, 25}.”

A partir daí, o passo a passo pode ser resumido em:

(1) GPT 5.5 (Consolidated)	(2) GPT 5.6 Think (Itemized)
Não conseguiu processar o arquivo inteiro	Processou o texto inteiro, mas demorou mais tempo do que o 5.5 incluindo as fragmentações
Informou que o máximo de palavras que conseguiria processar seria entre 100 e 120 palavras	
Solicitamos a fragmentação do Texto original, o que resultou em 13 fragmentos	
Cada fragmento foi etiquetado individualmente	
O programa não conseguiu agrupar os fragmentos etiquetados	
A consolidação foi feita à mão	
Os itens etiquetados foram colocados cada um em uma linha	Os itens foram etiquetados mantendo-se alinhamento textual
e.g. I {3,906} was {22,30} left {33,902} , {}	e.g. I {3,906} was {22} left {24,30,33,902,907}, for {69} the {1} time {9,14}, on {69} perceiving {26,51,80,94,112,907,908,911}

for {49,69,901} the {1} time {9,17} , { } on {69} perceiving {26,907,112}	
--	--

Uma vez etiquetados os dois arquivos, solicitamos que o GPT 5.6 fizesse uma comparação entre os dois arquivos etiquetados, a partir do seguinte comando:

“Compare this document (text_consolidated.txt) to your output (00000209_16_tagged.txt). Make a list of their differences”

O output pode ser resumido da seguinte forma:

- Os itens lexicais dos dois textos são idênticos
- 660 unidades apresentaram tag sets idênticos
- A etiquetagem apresentou a seguinte variação:
 - 37 diferenças de tokenização ou segmentação
 - 268 etiquetas diferentes
 - 216 marcas de pontuação etiquetadas de forma diferente
 - 48 diferenças superficiais, envolvendo aspas, estilo de apóstrofe, letra maiúscula, mas com etiquetas idênticas

A fim de reorganizarmos a questão da pontuação, foi solicitado um novo arquivo, com os itens separados por linhas e a pontuação marcada sem etiqueta, com o seguinte prompt:

itemize the tagged set updated with one lexical item per line, including its correspondent tags, leave punctuation marks in independent lines, even when they do not have a tag or tag set, following it order in the original text. like this:

I {3,906}
was {22,30}
left {33,902}
, { }
for {49,69,901}
the {1}
time {9,17}
, { } on
{69}
perceiving {26,907,112}

A partir daí, solicitou-se uma nova compração em forma de tabela, com o seguinte prompt:

Compare Text_Consolidated(1).txt to 00000209_16_tagged_itemized.txt.
Make a comparative table of their differences

O output foi um arquivo Excel nomeado comparison_Text_Consolidated_vs_itemized.xlsx, em anexo a este relatório.

A análise da tabela contrastiva pode ser resumida da seguinte maneira:

- tag order
- Formatting markers
- Punctuation/Text
- Tag order + Tokenization
- Tag set
- Tag set + Tokenization
- Tokenization

Os seguintes casos foram desprezados, conforme as justificativas:

- 1) Tag order - as etiquetas são as mesmas, apenas colocadas em ordem distinta e.g.
facing {24,907,112} versus facing {24,112,907}
- 2) Formatting markers referem-se aos travessões
- 3) Punctuation/text referem-se às aspas

Dessa forma, restaram para a análise as seguintes situações

A) Tokenization

Os problemas relacionados com Tokenization envolvem as contrações. A etiquetagem feita pelo (1) GPT 5.5 considerou itens distintos, já a etiquetagem feita pelo (6) GPT 5.6 considerou como um único item:

DIFFERENCE TYPE	Context	GPT 5.5 - Consolidated	GPT 5.6 - Itemized
Tag order + Tokenization	Everything . It [doesn't] matter . I've	does {83,109} + n't {107}	doesn't {83,107,109}
Tag order + Tokenization	damned . And [that's] why , to	that {7b,906} + 's {22,107,109}	that's {7b,22,107,109,906}

Nos exemplos acima, embora haja a diferença no processo de etiquetagem as etiquetas são as mesmas. Todavia, os exemplos a seguir, apresentam diferenças substanciais:

DIFFERENCE TYPE	Context	GPT 5.5 - Consolidated	GPT 5.6 - Itemized
Tag set + Tokenization	. " As [I've] told you ,	I {3,906} + 've {23,31a,107}	I've {3,23,107,109,906}
Tag set + Tokenization	" " Because [you've] made up your	you {4,906} + 've {23,31a,107}	you've {4,23,107,109,906}
Tag set + Tokenization	only way . [What's] ' out ,	What {68,903} + 's {22,107,109}	What's {8,22,68,107,109,903,906}

Tag set + Tokenization	" Well , [there's] that awful reason	there {42,78} + 's {22,107,109}	there's {22,107,109}
------------------------	--------------------------------------	---------------------------------	----------------------

Sugestão A:

É preciso deixar claro no prompt do tag set como o a contração deve ser estritamente considerada, seja como parte integrante do item lexical ou não. Por exemplo:

Para **doesn't** deveria ser **does {83,109} + n't {107}** ou **doesn't {83,107,109}**.

Defendemos a primeira opção com etiquetas separadas.

B) Etiquetas diferentes

A tabela contrastiva apresentou 319 itens com etiquetas diferentes. Os problemas de Tag set são os que podem causar maiores problemas para a replicabilidade de estudos que contem com a etiquetagem pelo GPT. Podemos destacar os seguintes itens recorrentes:

Caso B.1. etiqueta para ponto de interrogação (?)

O GPT 5.5 etiquetou o ponto de interrogação, exclamação e algumas aspas como 67 (wh-questions all clauses tagged as wh-questions) e 903 (allwh = all wh-structures (wh_ques, wh_cl)); enquanto o GPT 5.6 deixou sem etiqueta.

Exemplos

DIFFERENCE TYPE	Context	GPT 5.5 - Consolidated	GPT 5.6 – Itemized
Tagset para (?)			
	— _you [?] _ " "	? {67,903}	? {}
	you a reason [?] " " For	? {67,903}	? {}
	your leaving us [?] Yes ; they	? {67,903}	? {}
	the lost ? ["] " Of the	" {67,903}	" {}
	them — ? ["] " She wants	? {67,903}	? {}
	them — ? ["] " She wants	" {67,903}	" {}
	write — ? ["] Remembering she couldn't	? {67,903}	? {}
	write — ? ["] Remembering she couldn't	" {67,903}	" {}
	least known what [!] " Mrs .	! {67,903}	! {}

Sugestão B.1:

É preciso deixar claro no prompt quais etiquetas devem seguir essas marcas de pontuação especificamente

Caso B.2. etiquetas que consideram um item tanto por sua especificidade quanto por sua generalidade (all), mas de forma diferente pelos dois programas

Exemplos

DIFFERENCE TYPE	Context	GPT 5.5 - Consolidated	GPT 5.6 – Itemized
	The tears were [again] in her eyes	again {43}	again {42,43}
	I had not [fully] intended , and	fully {42,70}	fully {42,70,915}
	— I can [hear] you all .	hear {26,907}	hear {26,80,907}

Sugestão B.2: que todas as etiquetas “all”, verb all (xxx) sejam uma tarefa do counter (pós-etiquetagem) e não do tagging

Caso B3. Expressões que poderiam ser consideradas como tal e não como itens individuais

Of course
At last
In the least
Make up one’s mind
Take into account
After all

DIFFERENCE TYPE	Context	GPT 5.5 - Consolidated	GPT 5.6 – Itemized
Expressões que foram separadas	Oh , of [course] , of course	course {9,14}	course {42,73,915}
	course , of [course] ! ’ —	course {9,14}	course {42,73,915}
	” I at [last] answered ; and	last {42}	last {42,43}
	never in the [least] known what !	least {42}	least {42,71,915}
	really in the [least] know them .	least {42}	least {42,71,915}
	I’ve made [up] my mind	up {42}	up {88}
	Because you’ve made [up] your mind ?	up {42}	up {88}
	matter . I’ve [made] up my mind	made {24,907}	made {26,31a,907}
	Because you’ve [made] up your mind	made {24,907}	made {26,31a,907}
	to take into [account] that they were	account {9,13}	account {9,13,51,94,908,911}
	whole thing . [After] all ,	After {69}	all {42,45,901}
	thing . After [all] , ” I	all {42}	all {42,45,901}

Sugestão B.3: criar etiquetas específicas para expressões, pois quando separadas geral inconsistência na etiquetagem

Caso B4. “TIME”

A palavra “time” foi considerada por ambas versões como 9 (all nouns) mas o GPT 5.5 considerou também como 17. Quantity nouns, enquanto o GPT 6 considerou como 14. other abstract nouns

DIFFERENCE TYPE	Context	GPT 5.5 - Consolidated	GPT 5.6 – Itemized
Tag diferentes para time	, for the [time] , on perceiving	time {9,17}	time {9,14}
	had by this [time] formed the habit	time {9,17}	time {9,14}

Sugestão B.4: desambiguar. Deixar claro o quê cada item significa

Caso B5. Etiketadores consideraram aspectos diferentes para adicionar os tags e não todos. Algumas vezes, consideraram outros indicativos na frase para marcar o tempo verbal

DIFFERENCE TYPE	Context	GPT 5.5 - Consolidated	GPT 5.6 – Itemized
Been foi categorizado como present perfect	child who has [been] expelled — ”	been {22,31a}	been {22}
Been foi categorizado como past perfect	had I not [been] prepared . I	been {22,31b}	been {22}
Expeted recebeu etiqueta de simple past e past perfect, além das genéricas	had so perfectly [expected] that the return	expected {26,907,30}	expected {26,31b,52,80,94,907,908,911}
GPT 5.5 marcou past perfect; gpt 5.6 marcou participio	I [had] then to come	had {23,31b}	had {21,23,30,900}
GPT 5.5 marcou past perfect; gpt 5.6 marcou passado	” My question [had] a sarcastic force	had {23,31b}	had {23,30}
GPT 5.5 marcou condicional; gpt 5.6 generalizou	away from me [had] I not been	had {48,901}	had {23}
GPT 5.5 generalizou; gpt 5.6 marcou past perfect e generalizou	But what had [happened] to you ?	happened {79,907}	happened {31b,79,907}

Caso B6 - Erros na etiquetagem

1. *Allusion* recebeu etiqueta de verbo pelo GPT 5.5

Context	GPT 5.5 - Consolidated	GPT 5.6 – Itemized
they made no [allusion] to my having	allusion {9,25}	allusion {9,10,14}

--	--	--

2. *Down* recebeu etiqueta de general adverbs, activity transitivity phrasal verbs e occurrence phrasal verb individualmente e break recebeu outra etiqueta

Context	GPT 5.5 - Consolidated	GPT 5.6 – Itemized
engage to break [down] on the first	down {42}	down {85}
, in consequence break [down] . The tears	down {42}	down {90}

3. *How* recebeu etiqueta 68. wh-clauses all clauses with wh-complementizer, pelo GOT 5.5 mesmo estando no início de uma pergunta, sendo, portanto 67.

Context	GPT 5.5 - Consolidated	GPT 5.6 – Itemized
up . “ [How] do you communicate	How {68,903}	How {67,903}

4. *Inconsistência entre os modelos*

Ou seja, há inconsistência entre as classificações feitas pelos modelos.

Context	GPT 5.5 - Consolidated	GPT 5.6 – Itemized
now clearly so [many] of these for	many {17}	many {8,906}

MANY recebeu tag de pronome nominal e substantivo quantitativo, em cada um dos modelos. As duas classificações me parecem corretas, mas há que ser uma e a outra.

Context	GPT 5.5 - Consolidated	GPT 5.6 – Itemized
can hear you [all] . But nonetheless	all {42}	all {8,906}
thing . After [all] , “ I	all {42}	all {42,45,901}

ALL recebeu tag de pronome general adverbs pelo GPT 5.5 e apenas no segundo exemplo no GPT 5.6., o qual também incluiu pronome nominal (8); conjunção adverbial (45), allconj (901) e allpro (906). De fato, *ALL* é pronome no primeiro exemplo e advérbio no segundo, mas faz parte de uma expressão.

Comportamento semelhante pode ser visto nas etiquetas conferidas a *AWAY*

Context	GPT 5.5 - Consolidated	GPT 5.6 – Itemized
the “ put [away] ” — of	away {42}	away {9,12}
fairly have fallen [away] from me had	away {42}	away {84}

Home recebeu etiqueta de substantivo (9; 15) pelo GPT 5.6 quando exerce função de advérbio (42; 78)

Context	GPT 5.5 - Consolidated	GPT 5.6 – Itemized
. I came [home] , my dear	home {42,78}	home {9,15}

5. *Incongruência do tag . GPT 5.6 apresentou a etiqueta correta*

Context	GPT 5.5 – Consolidated ERRADA	GPT 5.6 – Itemized CORRETA
“ But — [a] — which ?	a {2} 2. Indefinite article: a	a {110} 110. prtcle = discourse particles, e.g. now, well, anyway
bribed her to [silence] ; a silence	silence {25,907}	silence {9,14}
silence ; a [silence] that , however	silence {9,25}	silence {9,14}
	25. communication verbs e.g., acknowledge, answer, claim, discuss allverb = all lexical verbs (actv, commv, mentalv, causev, occurv, existv, aspectv), e.g. produce, report, think, occur, exist	9. all nouns: all words identified as nouns by automatic tagger 14. other abstract nouns e.g., advantage, background, culture, model

6. *Incongruência do tag: GPT 5.5 apresentou a etiqueta correta*

Context	GPT 5.5 – Consolidated CORRETA	GPT 5.6 – Itemized ERRADA
then to come [back] to meet a	back {42} 42. general adverbs	back {84} – etiquetou apenas BACK, mas considerou a expressão 84. act_ipv = activity intransitive phrasal verbs, e.g. go on, come back
please them — [so] long as they	so {49,901}	so {42}
that note ; [so] that even now	so {49,901}	so {42}
He’s exquisite — [so] it can be	so {49,901}	so {42,45,901} 42. general adverbs 45. adverbial conjuncts e.g., however, therefore, thus, including, for example, 49. subordinating conjunctions (other) e.g., as, except 901. allconj = all conjunctions (o_and, p_and, sub_cnd, sub_othr, conjuncts), e.g. and, but, if, although, however

7. GPT 5.6 colocou todos os tags possíveis, inclusive alguns errado (Surtou)

Context	GPT 5.5 - Consolidated	GPT 5.6 – Itemized
---------	------------------------	--------------------

he thinks I'm [afraid] to — and	afraid {36,905}	afraid * {36,55,98,905,909,913,914}
		55, por exemplo: that-clause controlled by attitudinal adjective e.g., I'm afraid that..., They must be aware that..., You're surprised that...
yes , they [asked] me to say	asked {25,81,907,30}	asked {25,30,59,82,907,912,914}
	25. communication verbs e.g., acknowledge, answer, claim, discuss 81. pub_vb = public verbs, e.g. say, report, claim, assert 907. allverb = all lexical verbs 30. simple past tense e.g., they claimed, she concluded, he found, I reported	59. to-clause controlled by speech verb e.g., ask <someone> to..., claim to..., show how to.. 82. sua_vb = suasive verbs, e.g. ask, insist, recommend, suggest 912. all_vto = to-clauses controlled by verbs 914. all_to = all to-clauses (all_vto, all_jto)
[Because] you've made up	Because {111}	Because {49,111,901}
I see her [best] : facing the	best {42,70}	best {42}
	70. amplifr = amplifier adverbs, e.g. absolutely, entirely, completely	
were now clearly [so] many of these	so {42}	so {42,70,915}
— when he's [so] clever and beautiful	so {42}	so {42,70,915}
		Todas as possibilidades: 42. general adverbs 70. amplifr = amplifier adverbs, e.g. absolutely, entirely, completely 915. all_advl = all stance and degree adverbials (amplifr, downtone, atadvl, fctadvl, lklydvl, nonfadvl), e.g. completely, probably, unfortunately

* A questão é: a etiqueta deve ser atribuída só a afraid ou à frase?

Conclusão:

Quando se considera um texto com 1.000 palavras etiquetadas pelos modelos GPT 5.5 gratuito e 5.6 pago, pode-se concluir que **não é possível confiar em nenhum dos modelos plenamente** para uma etiquetagem precisa.

Ainda que tenham recebido o mesmo texto e o mesmo prompt, os resultados foram 60% idênticos. Dos 40% de diferença, 10% consideramos irrelevantes. Todavia, 30% de erro parece-nos um índice alto.

O modelo 5.5 parece não considerar todas as possibilidades de *POS* ou *derived features* para cada item etiquetado. Já o 5.6 pago considera mais aspectos dos itens lexicais e,

portanto, atribui mais etiquetas, porém, algumas delas são erradas e algumas consideraram uma sequência de palavras ao etiquetar um único item. Neste relatório, apresentamos pontualmente algumas das discrepâncias que encontramos. O arquivo do Excell em anexo apresenta o resultado completo.

Uma possibilidade que talvez possa amenizar essas confusões seria processar a etiquetagem em duas etapas. Na primeira, considerar apenas as subcategorias e, numa segunda, computar as categorias gerais (ALL).