

Dimensões de Variação do Português Brasileiro

Relatório Científico

Antonio Paulo Berber Sardinha

Carlos Kauffmann

Cristina Mayer Acunzo

19 de dezembro de 2012

Documento de Descrição Detalhada

1 Essência e Natureza do Problema

O presente projeto visou a identificar as dimensões de variação do português brasileiro por meio da Linguística de Corpus, mais especificamente, da sua vertente conhecida por Análise Multidimensional (AMD, Biber, 1988). A AMD opera com o conceito de registro, que significa ‘uma variedade linguística definida por aspectos situacionais, incluindo o propósito do falante, a relação entre falante e ouvinte, e o contexto de produção’¹ (Biber, 2009 :823), podendo indicar desde gêneros específicos, como artigos acadêmicos, quanto variedades mais gerais, como ‘documentos oficiais’. Dimensões de variação são padrões de coocorrência de elementos lexicogramaticais que subjazem aos registros de uma língua (Biber, 2009). Como tal, capturam o espaço de variação dos textos, sintetizam-no e mostram a proximidade ou distância entre os registros investigados (vide apresentação das dimensões em **Error! Reference source not found.** abaixo). Um exemplo de dimensão de variação (da língua inglesa) é ‘Interação versus Informatividade’ (Biber, 1988), que indica que todos os textos dessa língua possuem essas características essenciais, que são a interação, de um lado, e a informatividade, de outro: textos interativos tendem a ser menos informativos e vice-versa.

Dado que há uma profusão de registros e textos na sociedade, surgem questões chave da variação *em larga escala*, tais como: (1) quais são os parâmetros de variação subjacentes aos muitos registros conhecidos, ou, em outras palavras, como podemos chegar a uma síntese dos elementos centrais dessa variação? (2) qual a variação entre textos de uma mesma variedade textual (por exemplo, entre uma dezena de dissertações de mestrado, ou entre dissertações de áreas distintas, como engenharia e letras)? (3) quais aspectos lexicogramaticais (voz passiva, expansão do grupo nominal, metáfora gramatical, etc.) distinguem registros próximos como comunicação oral e artigo científico, ou reportagem e notícia?

Tais perguntas podem ser respondidas por meio da Análise Multiaspectual Multidimensional (Multi-feature, Multi-dimensional Analysis) ou simplesmente Análise Multidimensional (Biber, 1985 et seq.). Questões como essas se tornaram especialmente prementes após a consecução do Corpus Brasileiro, projeto financiado pela FAPESP, que criou uma coletânea de um bilhão de palavras e milhares de textos falados e escritos de português do Brasil; consultas ao corpus

¹ ‘Register is used here as a cover term for any language variety defined by its situational characteristics, including the speaker’s purpose, the relationship between speaker and hearer, and the production circumstances.’

(gratuita na Internet, pelo endereço <http://corpusbrasileiro.pucsp.br/x>) deixam claro que os padrões lexicogramaticais do português brasileiro variam consideravelmente de um registro para outro e urge uma descrição dessa variação.

Pesquisas anteriores promoveram a identificação de dimensões de diversas línguas, como o inglês (Biber, 1988; Crossley & Louwerse, 2007; de Mönnink, Brom, & Oostdijk, 2003; Lee, 1999), o coreano (Kim & Biber, 1994), o somali (Biber & Hared, 1994), o nukulaelae tuvalan (Besnier, 1988), o gaélico (Lamb, 2008) e o espanhol (Biber, Davies, Jones, & Tracy-Ventura, 2006; Parodi, 2007); contudo, a variação dimensional da língua portuguesa ainda não havia sido realizada, e preenchemos essa lacuna (no tocante à variante brasileira) por meio deste projeto.

A Análise Multidimensional é uma metodologia nascida na Linguística de Corpus, que é a área de investigação linguística responsável pela análise de corpora eletrônicos, com o auxílio de ferramentas computacionais (Baker, 2009; Berber Sardinha, 2004, 2009, 2005; Biber, Conrad, & Reppen, 1998; Lüdeling & Kytö, 2009; McEnery & Wilson, 1996; Sinclair, 1991; Teubert & Krishnamurthy, 2007). Corpora, por sua vez, são grandes quantidades de texto, coletadas criteriosamente e mantidas em formato de computador, com o propósito de servirem à pesquisa linguística (Berber Sardinha, 2004). Os corpora são formados, por definição, por textos de um ou mais gêneros (ou outra variante discursiva). A AMD viabiliza a análise de grandes corpora (tal é a abundância de textos e variantes textuais na sociedade) e permite chegar a um sistema de identificação das dimensões complexo o bastante para dar conta, ao mesmo tempo, da profusão de gêneros e das relações que os textos e gêneros estabelecem entre si. Essa identificação é levada a cabo por meio da anotação automática e semi-automática de variáveis relevantes para a caracterização dos gêneros, com o subsequente agrupamento e interpretação dessas variáveis em fatores, que são agrupamentos de textos que possuem padrões de coocorrência de variáveis definidos estatisticamente.

2 Objetivos

O objetivo geral deste projeto foi identificar as dimensões de variação do português brasileiro, por meio da Análise Multidimensional.

Os objetivos específicos foram:

1. Descobrir as variáveis lexicogramaticais relevantes para descrição da variação textual do português brasileiro.
2. Verificar a pertinência do emprego de variáveis colocacionais (bigramas, trigramas e quadrigramas) na composição das variáveis do estudo.

3. Identificar os fatores estatísticos responsáveis pela variação textual do português brasileiro e a parcela de variação correspondente a cada fator.
4. Interpretar os fatores por meio de critérios discursivos, funcionais, comunicativos ou de outra natureza conforme necessário para dar conta dos dados que emergirem da análise fatorial.
5. Desenvolver e disponibilizar na web material de apoio para a realização de AMD do português, como o corpus, ferramentas computacionais online e tutoriais, visando à divulgação da área entre os países falantes do português.

3 Metodologia

As etapas da análise foram as seguintes (a partir de Biber, 2009, pp. 825-826):

1. Coleta de um *corpus* apropriado para o projeto em questão.
2. Pesquisa bibliográfica para determinar as características linguísticas relevantes para o projeto, e para saber como interpretar essas características em termos funcionais e discursivos.
3. Utilização e/ou desenvolvimento de programas de computador para anotar o *corpus* automática ou semi-automaticamente.
4. Anotação do *corpus* e subsequente verificação da acuidade desse processamento.
5. Emprego e/ou criação de programas de computador para contar as características linguísticas anotadas e normalizar as contagens em termos de ocorrências por mil palavras.
6. Realização de análise fatorial para extração dos fatores subjacentes aos dados.
7. Interpretação dos fatores em termos de dimensões de variação.
8. Cálculo dos escores de fator ou de dimensão para cada texto e para cada registro, a fim de ranquear os textos e registros relativamente uns aos outros em cada dimensão.

As etapas de 1 a 5 são descritas nesta seção, pois referem-se à metodologia de pesquisa. Já as etapas de 6 a 8 são relatadas na próxima seção pois dizem respeito aos resultados da pesquisa.

3.1. Coleta do *corpus*

Foram coletados dois *corpora* diferentes durante o projeto: o piloto e o final. O *corpus* piloto foi usado para a pesquisa inicial, na qual foram testadas as etapas da metodologia com a finalidade de identificar problemas e propor soluções visando à análise definitiva.

Tabela 1: Composição e extensão do *Corpus* piloto

Registro*	Textos	Palavras (<i>tokens</i>)
AULAS	6	29.290
SESSÕES DO CONGRESSO	20	713.737
CONVERSAÇÃO	11	16.156
ENTREVISTAS DE TV	50	660.069
NOTÍCIAS DE TV	150	39.671
PROGRAMAS DE RÁDIO	10	82.538
CONVERSAÇÃO TELEFÔNICA	30	10.795
Artigos de pesquisa	80	270.884
Cartas de negócio	105	25.490
Crônicas	188	146.732
Editoriais	100	54.300
Ficção	205	394.067
Receitas culinárias	1.000	163.309
Reportagem jornalística	398	186.460
Teses e dissertações	20	591.802
Total: 15 registros	2373	3.385.300

* Os registros grafados em letras maiúsculas são falados, e os demais, escritos.

A versão final do *corpus* veio principalmente completar duas lacunas observadas na análise. A primeira era a necessidade de expandir o número de registros, para melhor representar a variedade textual do português brasileiro. Expandimos a quantidade de registros incluída no *corpus*, de 15 para 47. Segundo Biber (1990), para representar a variedade de textos de uma língua, a principal preocupação deve ser a variedade de registros², em vez da quantidade de textos total do *corpus*. Com base em pesquisa empírica, Biber contrastou *corpora* de tamanhos diferentes com o intuito de verificar a capacidade de cada um de replicar as dimensões de variação do inglês obtidas com o *corpus* de 481 textos do estudo de 1988 (Biber, 1988). Os resultados mostraram que *corpora* com $\frac{1}{4}$ ou $\frac{1}{2}$ dos textos (120 ou 240 textos, respectivamente) do *corpus* original conseguiram reproduzir a análise fatorial obtida com o *corpus* maior, desde que contivessem a mesma proporção dos registros do *corpus* original. Por outro lado, um *corpus* com mais textos de alguns poucos registros não conseguiu retornar a análise fatorial original.

A segunda lacuna era determinar o tamanho de cada *subcorpus*, mais precisamente a quantidade de textos de cada registro, pois os resultados mostraram que os *subcorpora* com grande número de textos causavam viés nas dimensões. Tais *corpora* criavam, por assim dizer, dimensões próprias. Isso aconteceu visivelmente com as receitas culinárias, que respondiam por 42% da quantidade de textos do *corpus*, mas por apenas 5% das palavras³. Isso se dá porque a análise fatorial, na Análise Multidimensional, tem o texto como unidade de trabalho e não a palavra. A análise fatorial busca conjuntos de características semelhantes ao cruzar suas ocorrências nos vários textos. Se há muitos textos de um mesmo registro e se esses textos possuem características linguísticas com frequências semelhantes (o que é de se esperar), então essas características e por conseguinte esses textos serão agrupados num mesmo fator. Esse é um problema de viés, pois o peso de cada registro no *corpus* não pode ser tão grande que se crie um fator específico para ele. Essa foi uma lição valiosa, pois não há na literatura de Análise Multidimensional informação a respeito desse tipo de viés. A Análise Multidimensional

² the underlying parameters of text-based linguistic variation (as represented by the factorial structure) can be replicated in a relatively small corpus, *if* that corpus represents the full range of variation. In contrast, larger corpora are not adequate for overall analyses of textual variation if they fail to represent the range of variation.

³ As receitas ainda se destacam na dimensão 4 obtida com o *corpus* final, mas em menor grau do que anteriormente, com o *corpus* piloto. Como a quantidade de textos está balanceada, podemos atribuir esse destaque das receitas nessa dimensão a uma característica inerente ao registro e não a um viés da coleta.

tem salvaguardas contra o viés de tamanho de texto (a normalização das frequências) e contra a frequência das variáveis (a padronização das frequências normalizadas), mas não contra o peso relativo de cada registro no *corpus*.

Assim, partimos para a versão final do *corpus* com o critério de balancear sua composição em torno dos número de textos de cada registro. Segundo Biber (comunicação pessoal, 2012), é importante que o desenho do *corpus* seja baseado em princípios⁴ e que não seja oportunista. Não há na literatura de Linguística de *Corpus* critérios unânicos relativos à quantidade ideal de textos para representar um registro. Biber (1990, p. 263) verificou com base em pesquisa empírica que corpora de 10 textos são capazes de representar as características linguísticas principais da língua inglesa⁵. Dessa forma, estabelecemos o princípio de ter 20 textos em cada registro, o dobro do mínimo sugerido por Biber (1990). A composição do *corpus* final aparece nas Tabela 2 Tabela 3.

Tabela 2: Composição e extensão do *corpus* final⁶

Registro*	Textos	Palavras
Apostilas de cursinho	20	15.411
Artigos acadêmicos	20	92.148
Atas de reunião	20	25.929
Blogs	20	31.486
Bulas de remédio	20	16.061
CANÇÕES	20	11.990

⁴ 'corpus design must be principled'.

⁵ The 10-text samples thus consistently provide good representations of these genres with respect to both their overall central tendency (the mean score [...]) and their overall range of variation (the standard deviation [...]).

⁶ Doravante, quando não houver especificação do tipo de *corpus* (piloto ou final), entenda-se *corpus* final.

Cartas de negócios	20	12.720
Contos	20	57.362
Contratos	20	44.562
CONVERSAÇÃO	20	93.470
Crônicas	20	21.403
DIÁLOGOS DE LIVROS DIDÁTICOS	20	9.447
DISCURSOS POLÍTICOS	20	44.591
Editoriais	20	11.233
Emails	20	11.223
ENTREVISTAS DE TV	20	263.821
ENTREVISTAS PUBLICADAS	20	28.175
ENTREVISTAS SOCIOLINGÜÍSTICAS	20	152.788
Facebook	20	11.022
Ficção geral	20	403.796
Ficção para jovens	20	543.200
Horóscopo	20	12.637
Instruções de jogos	20	16.260
Leis e normas	20	125.531
Licitações	20	127.239
Liturgia da missa	20	66.995
Livros escolares	20	12.732

Livros não ficção	20	55.028
Livros texto	20	1.234.790
NOTÍCIAS DE TV	20	11.453
NOVELAS DE TV	20	93.627
Piadas	20	9.310
Programas de governo	20	29.724
PROGRAMAS DE RÁDIO	20	91.335
Provas de vestibular	20	33.937
Quadrinhos	20	25.937
Receitas culinárias	20	9.591
Reportagem jornalística	20	11.467
Revista de celebridades	20	25.738
Revista de notícias	20	19.850
Rótulos de embalagem	20	9.183
SESSÕES DO CONGRESSO	20	641.080
TELECONFERÊNCIAS DE NEGÓCIOS	20	106.076
Teses e dissertações	20	617.943
Textos de enciclopédia	20	13.690
Twitter	20	11.027
Websites	20	28.338
Total: 47 registros	940	5.342.356

* Os registros grafados em letras maiúsculas são falados, e os demais, escritos.

Tabela 3: Composição do *corpus* final em termos do modo de produção

Modo	Registros	Textos	Palavras
Falado	12 (26%)	240 (26%)	1.547.853 (29%)
Escrito	35 (74%)	700 (74%)	3.794.503 (71%)
Total	47	940	5.342.356

Comparativamente, esse *corpus* é o primeiro no número mínimo de textos por registros, o segundo em termos do número de registros e de textos, e o terceiro no total de palavras nas pesquisas referentes a variedades linguísticas nacionais, conforme mostra a Tabela 4.

Tabela 4: Composição de *corpora* usados em Análise Multidimensional

Língua	Registros (escritos / falados)	Textos	Textos por registro	Total de palavras
Inglês (1)	23 (17/6)	481	6 a 80	960.000
Inglês (2)	66 (41/25)	430	2 a 133	2.006.093
Inglês (3)	22 (4/18)	Não informado	Não informado	6.287.734
Tuvaluan	7 (2/5)	222	12 a 70	152.771
Coreano	22 (12/10)	150	5 a 10	135.500
Somali	33 (23/10)	604	3 a 49	600.000
Espanhol (4)	19 (8/11)	4049	16 a 791	20.301.847
Espanhol (5)	3 (2/1)	90	4 a 74	1.466.744
Português brasileiro	47 (12/35)	940	20	5.342.356

(1) Biber (1988)

(2) Lee (1999). Seu estudo testou diversos números de variáveis.

(3) Crossley e Louwerse (2007). O artigo relata dois estudos com os mesmos dados, mas com números de variáveis diferentes. Referimo-nos ao estudo 2, considerado mais robusto.

(4) Biber et al. (2006; 2007)

(5) Parodi (2007)

O *corpus* final foi limpo inicialmente por meio de um programa de computador criado especialmente para essa tarefa. Em seguida, foi normatizado a mão. Essa etapa consumiu muito tempo e envolveu trabalho de terceiros.

Foi preciso estabelecer um critério referente à definição de texto, em função da variável razão forma-ocorrência (*type-token ratio*). Essa variável foi definida de tal modo que a contagem seja feita entre as primeiras 400 palavras (*tokens*) do texto, seguindo o mesmo critério de Biber (1988). Isso coloca uma coerção no tamanho mínimo do texto como sendo de 400 palavras. A razão forma-ocorrência é sensível à extensão do texto, porque as palavras tendem a se repetir à

medida que o texto se alonga: o mesmo ‘estoque vocabular’ vai sendo reutilizado e menos palavras diferentes vão sendo introduzidas. Quanto menor o texto, menor a oportunidade para a reutilização das palavras já mencionadas no texto. Por conseguinte, a razão forma-ocorrência tende a aumentar, simplesmente porque o texto é curto. Isso não é um problema quando se analisa apenas um registro ou quando se compara registros cujos textos têm tamanhos semelhantes, mas quando há grande variação no tamanho dos textos, isso causa um viés. Para evitá-lo, foi estabelecido o critério de que cada texto deveria ter no mínimo 400 palavras de extensão. Para isso, textos que não atingiam esse número foram concatenados a outros até que se chegasse a essa meta. Isso foi necessário com registros como twitter, receitas e piadas, cujos textos tendem a ser, por definição, menores do que 400 palavras.

3.2. Pesquisa bibliográfica

Foi conduzida uma extensa pesquisa bibliográfica em trabalhos referentes à língua portuguesa do Brasil, tanto em obras de referência como gramáticas quanto em trabalhos acadêmicos (livros, artigos, teses, dissertações, etc.) para determinar as variáveis a serem utilizadas na pesquisa. Além disso, foi feito um levantamento das características linguísticas empregadas na literatura de Análise Multidimensional de outras línguas, notadamente do inglês e do espanhol. A relação das características linguísticas proveniente desse levantamento bibliográfico foi então analisada para saber quais eram propícias à anotação automática. Isso gerou uma relação de 190 características linguísticas (vide anexo 1).

3.3. Anotação do *corpus*, contagem das características linguísticas e normalização das contagens

O *corpus* foi anotado com o *parser* Palavras (Bick, 2005), que identifica automaticamente centenas de características linguísticas. A Tabela 5 abaixo traz um resumo dos tipos de características identificadas.

Tabela 5: Resumo das características identificadas pelo etiquetador Palavras

Tipo de anotação	Quantidade	Exemplo
Classe de palavra	13	Substantivo, adjetivo, verbo, etc.
Subclasse de palavra	56	Tipo de substantivo, adjetivo, verbo, etc.
Flexão	7	Gênero, número, pessoa, etc.

Sintática	36	Sujeito, objeto, oração, etc.
Valência	24	transitivo, intransitivo, bitransitivo, etc.
Semântica	177	Atividades, eventos, objetos, etc.
Total	313	

Essas características foram então cruzadas com as determinadas pelo levantamento bibliográfico. Muitas disponíveis no etiquetador não eram relevantes, de acordo com a pesquisa bibliográfica, ao mesmo tempo que muitas consideradas relevantes não eram anotadas pelo etiquetador.

Devido a isso, foi necessária a criação de um programa pós-processador dos textos etiquetados, chamado de *TagCounter*, em *Unix shell*. Ele identificou as 190 características linguísticas destacadas no levantamento bibliográfico. Uma parte do programa aparece no anexo 2.

Foi criada uma versão em Java dele, que estará disponível à comunidade, gratuitamente, no sítio de divulgação do projeto (<http://corpuslg.org/gelc/gelc.php>), chamado *PalavrasCounter*. No anexo 3 aparece uma parte do arquivo de parâmetros de busca para contagem das variáveis de verbos, para uso com o *PalavrasCounter*.

Após a aplicação do *TagCounter* (ou do *PalavrasCounter*) nos textos etiquetados pelo parser *Palavras*, foi utilizado um *script*, desenvolvido no projeto, para criação da planilha com as contagens brutas. Esse *script* é chamado *make_spreadsheet.sh*. A planilha gerada foi então carregada no programa Microsoft Excel, em que foi aplicada esta fórmula para cálculo das frequências normalizadas: frequência normalizada = (frequência bruta / total de palavras no texto) x 1000.


A planilha com as contagens normalizadas foi carregada no programa SPSS for Mac 20 para as análises estatísticas, descritas na seção a seguir.

4 Resultados

A análise fatorial é uma etapa central da abordagem, porque nela são definidos quantas e quais são as dimensões de variação. O método de extração recomendado por Biber (1988) e adotado nesta pesquisa foi o Principal Axis Factoring (Eixo Principal). A extração foi realizada no programa SPSS for Mac 20.

A primeira extração fatorial foi feita sem rotação, para descobrir o número de fatores presentes nos dados. A rotação altera a composição dos fatores, mudando variáveis de um fator para outro a fim de tornar a composição de cada fator mais distinta dos demais. Por isso, antes de realizar a rotação, é preciso determinar quantos fatores é preciso extrair. Isso é feito pela observação dos eigenvalues ou univalores da extração. Esses valores foram plotados em um gráfico conhecido como *scree plot*, ou de sedimentação, a fim de permitir a visualização do primeiro ponto (da esquerda para a direita) em que há desaceleração marcante do percentual de variação acrescido por cada fator. Esse gráfico aparece na Figura 1.

Figura 1: Gráfico de sedimentação



Notou-se uma desaceleração entre os fatores 6 e 7, posição em que a linha se torna praticamente reta. Assim, foi escolhido o número 6 como o total de fatores a serem extraídos.

Em seguida, foram retiradas da análise variáveis cujas comunalidades eram menores do que 0,2, que é o valor mínimo sugerido por Biber (1995, p. 138) – embora ele sugira 0,15 como o valor mínimo em Biber (2006, p. 183)⁷. A retirada dessas variáveis torna a solução fatorial mais robusta, porque se baseia nas variáveis que mais contribuem para a variação entre os textos.

⁷ “‘Communality estimates’ produced by the statistical analysis indicate the extent to which a given feature participates in the overall pool of shared variance accounted for by the factor analysis. In general, features with communalities below .15 do not have meaningful factor loadings on any factor.”

Feito isso, a extração rotacionada por Promax foi realizada com seis fatores, o que produziu a matrix de padrão (pattern matrix) dos fatores mostrada na Tabela 6.

Tabela 6: Matriz de padrão (*pattern matrix*) da solução fatorial rotacionada para seis fatores

Variável*	1	2	3	4	5	6
prn2obl	.910					
vb1	.862					
vbment	.827					
vbfutir	.821					
prpall	-.776					
prn2sngsubj	.763					
artdef	-.739					
vbpriv	.702					
vbact	.689					
advnao	.674					
ncomp	-.651					
prn1sngsubj	.633		.314			
advtime	.629					
prn1obl	.622					
prnqtf	.616	.352				
adjeval	.612					-.318
prnpos	.605		-.431			.424
adjattr	-.589					
advints	.552					-.341
qsqu	.539					
wl	-.529					
advampl	.522					-.340
nabst	-.521			-.331		
adjtopi	-.511					
nominlzsubj	-.505					
vbpastprt	-.497					
advemph	.476					
vbqueindic	.467		.316			
adjpred	.456	.353				
adjrela	-.422				.303	
vbinf	.407					
clpassless	-.377					
advmanner	.373			.345		
vbcomm	.356					
vbgerall	.345					
mdprecisar	.338					
clqueeadv	.337					
vbproginf	.330					
advneg	.320					
prnqualcujo	-.315					
vbprogphr	-.309					
prnnomsubj	.308					
focusmkr						
ntech						
advdown						
adjsize						

advnonf						
clqueadjeval						
wrcount						
advatt						
mdparecer						
prn2plusubj						
vbprog						
vbcogninf						
vbdesrinf						
nfactlinf						
nnonfcque						
adjattique						
nounque		.593				.308
prnque		.529				.340
advcomp		.473				
ncogn		.451				
nqueinfcl		.447				
clinfadj		.447				
clqueeprp		.426				.380
prndem		.406	.362			
clinfprp		.395				
adjque		.378				
clinfadjease		.334				
advhedg		.331				
artindef		.325			-.320	
vbfutpret		.311				
cjadv		.310				
nprop						
prnrelprep						
vbocc						
clinfadjeval						
nliklhque						
vbcognque						
cjtemp						
nfactlque						
adjliklinf						
vbCU						
vbcausinf						
nnonfcinf						
clqueadjcert						
clinfadjcert						
vbdesrque						
vbspchque						
nliklhinf						
clinfadjwill						
adjfactque						
clqueadjease						
cjcnfm						
qsttag			.795			
contrac			.714			
discmrkr	.350		.671			
qsyn	.421		.547			-.330
prn3sngsubj			.498			

prn3plusubj			.481			
cjcncl			.475			
advpl	.460		.462			
adjpre			-.357			
ttr			-.346			
mdter			.315			
ngrpi						
advcmpd						
nanim						
prn1plusubj						
vbquesubjc						
vbsubpres				.821		
vbimp				.774		
nconc				.565		
subjdrop	.343			.545		
vbfacil				.485		
cjcoorcls				.465		
adjtime						
adjcolr						
mdconseguir						
vbsubfut	.323				.616	
cjou					.611	
vbpast					-.554	
vbfutpres					.513	
mddever					.474	
mdpoder		.336			.426	
cjcond	.313				.390	
advlikl					.389	
vbimpf					-.375	
adjaffi	-.336				-.355	
cjcoorphr					.322	
vbsubpast					-.308	
nplac					-.301	
nattitque						
advsplit						
objprnrare						.628
vb2						.466
cjfinal						.413
prn3obl		.343				.371
vbpubl						.327
mdhaver						.311
adjsup						
nqTTY						
vbprobinf						
vbsua						
cjcncsv						
vbcausque						
clinfadjaff						

* A lista das variáveis com seus respectivos rótulos descritivos aparece no anexo 1.

Na matriz, aparecem apenas os pesos iguais ou maiores que 0,3, que é o valor mínimo sugerido por Biber (2006); as células em branco, portanto, possuem valor menor e foram omitidas, para

facilitar a visualização. O total de variáveis com peso maior ou igual a 0,3 é 93.

Depois disso, as frequências normalizadas foram padronizadas, de tal modo que a média de cada variável seja igual a zero. Todas as variáveis passam a ser medidas dentro da mesma escala. Esse passo garante que as variáveis menos frequentes no *corpus* não sejam discriminadas simplesmente porque são menos frequentes. As variáveis foram então renomeadas pela adição da letra Z diante do seu nome (por exemplo, vb1, a contagem normalizada de verbos de primeira pessoa, quando padronizada, passou a ser Zvb1).

As frequências padronizadas são usadas para calcular o escore de cada texto em cada dimensão. A fórmula para esse cálculo é a seguinte:

(variável do polo positivo 1 + variável do polo positivo 2 + variável do polo positivo n) – (variável do polo negativo 1 + variável do polo negativo 2 + variável do polo negativo n)

Para esse cálculo, cada variável é computada em apenas um fator, qual seja, aquele em que possui o maior peso absoluto (isto é, independente do sinal). Por exemplo, a variável prndem (pronomes demonstrativos) possui peso de 0,406 no fator 2 e de 0,306 no fator 3. Sendo assim, ela entra no cálculo do fator 2 apenas. Por outro lado, todas as variáveis com carga mínima de 0,3 são levadas em conta na interpretação dos fatores, mesmo que não tenham sido incluídas no cálculo do escore. Assim, a variável prndem é usada na interpretação tanto do fator 2 quanto do 3.

Com base nessa fórmula, os escores de cada texto, em cada fator, foram computados desta maneira:

Fator 1=(Zprn2obl + Zvb1 + Zvbment + Zvbfutir + Zprn2sngsubj + Zvbpriv + Zvbact + Zadvnao + Zprn1sngsubj + Advtime + Zprn1obl + Zprnqtf + Zadjeval + Zprnposs + Advints + Zqsqu + Advampl + Advemph + Zvbqueindic + Zadjpred + Zvbinf + Advmanner + Zvbcomm + Zvbgerall + Zmdprecisar + Zclqueeadv + Zvbproginf + Advneg + Zprnnomsubj) - (Zvbprogphr + Zprnqualcujo + Zclpassless + Zadjrela + Zvbpastprt + Znomnlzsubj + Zadjtopi + Znabst + Zwl + Zadjattr + Zncomp + Zartdef + Zprpall).

Fator 2=(Znounque + Zprnque + Advcomp + Zncogn + Znqueinfcl + Zclinfadj + Zclqueeprp + Zprndem + Zclinfprp + Zadjque + Zclinfadjease + Advhedg + Zartindf + Zvbfutpret + Zcjadv).

Fator 3=(Zqsttag + Zcontrac + Zdiscmrkr + Zqsyn + Zprn3sngsubj + Zprn3plusubj + Zcjcnci + Advpl + Zmdter) - (Zttr + Zadjpre).

Fator 4=(Zvbsubpres + Zvbimp + Znconc + Zsubjdrop + Zvbfacil + Zcjcoorcls).

Fator 5=(Zvbsubfut + Zcjou + Zvbfutpres + Zmddever + Zmdpoder + Zcjcond + Zadvlikl + Zcjcoorphr) - (Znplac + Zvbsubpast + Zadjaffi + Zvbimpf + Zvbpast).

Fator 6=(Zobjprnrare + Zvb2 + Zcjfinal + Zprn3obl + Zvbpubl + Zmdhaver).

Essas fórmulas produziram um escore para cada texto em cada um dos seis fatores. Por exemplo, para o registro 'artigos acadêmicos', os escores de texto no fator 1 são:

Tabela 7: Escores de texto do registro 'artigos acadêmicos' no fator 1

Texto	Escore no fator 1
wr-aa_01	-39.35
wr-aa_02	-32.32
wr-aa_03	-26.65
wr-aa_04	-20.98
wr-aa_05	-20.27
wr-aa_06	-1.44
wr-aa_07	-22.39
wr-aa_08	-17.17
wr-aa_09	5.20
wr-aa_10	-40.64
wr-aa_11	-30.27
wr-aa_12	-23.57
wr-aa_13	-24.91
wr-aa_14	-28.11
wr-aa_15	-28.01
wr-aa_16	-30.30
wr-aa_17	-24.30
wr-aa_18	-29.46
wr-aa_19	-27.16
wr-aa_20	-28.69

Esses valores formaram a base do cálculo dos escores de dimensão (ou escores de fator) de cada registro, que é a média dos escores dos textos de cada registro. No caso do registro 'artigos acadêmicos', a média dos escores é -24,539; este foi, portanto, o escore desse registro no fator 1.

Depois de computados os escores de texto e os escores de registro, foram calculadas as correlações entre esses escores, o que é conhecido por correlações entre fatores. A Tabela 8 apresenta os valores dessas correlações.


Tabela 8: Correlações entre fatores

Fator	1	2	3	4	5	6
1	1,000	0,165	0,482	0,235	-0,412	0,156
2	0,165	1,000	0,045	-0,027	-0,119	-0,148
3	0,482	0,045	1,000	-0,112	-0,362	0,232
4	0,235	-0,027	-0,112	1,000	-0,056	-0,193
5	-0,412	-0,119	-0,362	-0,056	1,000	-0,200
6	0,156	-0,148	0,232	-0,193	-0,200	1,000


Essas correlações medem a independência de cada fator em relação aos demais. O desejável é que os fatores sejam totalmente independentes uns dos outros, de tal modo que não haja correlação alguma entre eles (valor 0). Entretanto, como foi usada a rotação Promax, que permite correlação entre os fatores, não há, estritamente falando, independência total. Além disso, como se trata de pesquisa com textos, as variáveis usadas na pesquisa estão, por definição, correlacionadas, pois co-habitam os mesmos textos.

Os gráficos da Figura 2 mostram as correlações entre fatores referentes às pesquisas multidimensionais de variação de registro do inglês (Biber, 1988), espanhol (Biber & Tracy-Ventura, 2007) e do português brasileiro (relatada aqui). Foram plotados todos os valores obtidos, sem distinguir entre quais fatores havia a correlação, pois o intuito é comparar a magnitude da correlação e não quais fatores estão correlacionados. Os gráficos indicam que as correlações obtidas nesta pesquisa são similares aos das demais: o valor mais alto (independente do sinal) é 0,48, no inglês é 0,49 e no espanhol, 0,44; o segundo valor mais alto é 0,36, no inglês, 0,34 e no espanhol, 0,36; o terceiro é 0,24, assim como no inglês, e no espanhol, 0,27; o valor mais baixo é 0,03, 0,12 no inglês e 0,02 no espanhol. Dessa forma, pode-se concluir que os fatores extraídos nesta pesquisa estão dentro da normalidade no que tange à sua independência em relação aos demais.

Figura 2: Correlações entre fatores em pesquisas multidimensionais



Português brasileiro



4.1. Dimensões de variação

Na análise final, foram identificadas seis dimensões, a saber:

1. Produção com envolvimento *versus* produção com foco informacional
2. Argumentação
3. Oralidade *versus* letramento
4. Discurso procedural
5. Orientação temporal para o futuro *versus* orientação temporal para o passado
6. Discurso relatado

A seguir, são discutidas as propriedades de cada dimensão.

4.1.1. Dimensão 1: Produção com envolvimento *versus* produção com foco informacional

As características linguísticas que formam o polo positivo (produção com envolvimento) dessa dimensão são as seguintes:

Tabela 9: Características linguísticas do polo positivo da Dimensão 1

Característica		Variável	Peso
Pronome	Oblíquo de segunda pessoa	prn2obl	0.91
Verbo	Primeira pessoa	vb1	0.862
Verbo	Mentais	vbment	0.827
Verbo	Futuro perifrástico com 'ir'	vbfutir	0.821
Pronome	Segunda pessoa do singular, em posição de sujeito	prn2sngsubj	0.763
Verbo	Privados	vbpriv	0.702
Verbo	De ação	vbact	0.689
Advérbio	'Não'	advnao	0.674
Pronome	Primeira pessoa do singular, em posição de sujeito	prn1sngsubj	0.633
Advérbio	Tempo	advtime	0.629
Pronome	Oblíquo de primeira pessoa	prn1obl	0.622
Pronome	Quantificadores	prnqtf	0.616
Adjetivo	Avaliativo	adjeval	0.612
Pronome	Possessivos	prnpos	0.605
Advérbio	De intensidade	advints	0.552
Interrogativa	Com advérbio interrogativo	qsqu	0.539
Advérbio	Amplificadores	advampl	0.522
Advérbio	Enfatizadores	advemph	0.476
Oração	Subordinada com 'que' controlada por verbo no modo indicativo	vbqueindic	0.467

Adjetivo	Em posição predicativa	adjpred	0.456
Verbo	Infinitivo	vbinf	0.407
Advérbio	Modo	advmanner	0.373
Verbo	De comunicação	vbcomm	0.356
Verbo	Gerúndio	vbgerall	0.345
Modal	Precisar	mdprecisar	0.338
Oração	Subordinada com 'que' controlada por advérbio	clqueeadv	0.337
Verbo	Forma composta contínua precedida de infinitivo	vbproginf	0.33
Advérbio	De negação (exceto 'não')	advneg	0.32
Pronome	Nominal em posição de sujeito	prnnomsubj	0.308
(Advérbio	Lugar	advpl	0.46)
(Interrogativa	Sem advérbio interrogativo	qsyn	0.421)
(Outros	Marcadores discursivos	discmrkr	0.35)
(Outros	Omissão de sujeito	subjdrop	0.343)
(Verbo	Futuro do subjuntivo	vbsubfut	0.323)
(Oração	Coordenada (condicionais)	cjcond	0.313)

Este é o polo onde se concentra o maior número de características linguísticas. Os pronomes pessoais de primeira e segunda pessoas, bem como as frases interrogativas, revelam engajamento entre falante/escritor e ouvinte/leitor. Os amplificadores e enfatizadores salientam o conteúdo proposicional exposto. Os possessivos situam o discurso no âmbito dos participantes. Os verbos mentais e privados revelam a introspecção do falante. Advérbios sugerem a temporalidade do discurso, e o futuro perifrástico empresta um traço de informalidade ao discurso. As demais características desse polo se combinam para enfatizar o envolvimento ou interação entre locutor e interlocutor.

As características linguísticas que compõem o polo negativo dessa dimensão (produção com foco informacional) marcam uma preocupação com o provimento de informação. Substantivos abstratos, compostos e nominalizações em posição de sujeito conferem ao discurso uma grande carga informacional. Os adjetivos e preposições, por sua vez, completam a carga informacional do sintagma nominal. A oração reduzida apresenta conteúdo de forma sucinta. Palavras mais longas (extensão de palavra) são em geral de menor frequência e de maior complexidade do que palavras mais curtas. Voz passiva e particípio passado também indicam foco no conteúdo (a ação ou estado representado pelo verbo), em vez de no agente.

Tabela 10: Características linguísticas do polo negativo da Dimensão 1

Característica		Variável	Peso
Oração	Oração progressiva reduzida	vbprogphr	-0.309
Pronome	'Qual' ou 'cujo' como pronome relativo	prnqualcujo	-0.315
Outras	Voz passiva sem agente	clpassless	-0.377
Adjetivo	Relacional	adjrela	-0.422
Verbo	Particípio passado	vbpastprt	-0.497
Substantivo	Nominalização em posição de sujeito	nominlzsubj	-0.505
Adjetivo	Topical	adjtopi	-0.511
Substantivo	Abstratos	nabst	-0.521
Extensão	Média de palavra	wl	-0.529
Adjetivo	Em posição atributiva	adjattr	-0.589
Substantivo	Compostos	ncomp	-0.651
Artigo	Definidos	artdef	-0.739
Preposição	Todas	prpall	-0.776
(Adjetivo	Afiliativo	adjaffi	-0.336)

A distribuição dos escores médios de cada registro nessa dimensão aparece na Figura 3.⁸




Figura 3: Escores médios dos registros na dimensão 1

Os registros mais envolvidos são, na maioria, os falados, tais como as canções, os diálogos de livros didáticos, as novelas de TV, a conversação e as entrevistas sociolinguísticas. Há também registros escritos no polo positivo superior, como *Facebook*, quadrinhos e *emails*. Pode-se verificar, nessa distribuição, que o envolvimento entre os interlocutores está presente mesmo em registros monológicos, como as canções, ficção literária ou piadas. Neles, os escritores se valem

⁸ Nesta e nas demais figuras semelhantes, para distinguir entre os registros falados e os escritos, optou-se pela grafia dos primeiros em caixa alta.

de recursos linguísticos para simular a interação com o interlocutor, como se houvesse um diálogo face a face.

Os registros notadamente informacionais, por sua vez, são todos escritos. Isso ocorre devido à presença maciça das características linguísticas próprias desse polo concomitantemente com a ausência ou raridade de características que denotam o envolvimento com o interlocutor. Assim, registros como bulas de remédio, licitações, leis e normas são altamente nominais e densos e praticamente destituídos de uma preocupação com o engajamento do interlocutor.

As amostras abaixo ilustram a presença de características linguísticas do polo positivo dessa dimensão em canções e diálogos de livros didáticos.

Canções:

Eu já <advtime> fiz <vb1> <vbact> de tudo <prnqtf> pra te <prn2obl> convencer

Mande rosas vermelhas

Lindas pra você <prn2obl>

Falei <vb1> <vbcomm> de amor

Fiz uma canção

A_Lua se foi, nem vi <vb1> vi <vbment> vi <vbpriv> o Sol chegar <vbact> <vbinf>

Acreditei <vb1> <vbment> <vbpriv> <vbqueindic> que o tempo não <advnao> ia <vbfutir> passar

Diálogos de livros didáticos:

– E então, Vilma, você <prn2obl> <prn2sngsubj> está melhor <adjeval> melhor <adjpred> hoje <advtime>?

– Melhor? Infelizmente não <advnao>. Acho <vb1> Acho <vbment> <vbpriv> <vbqueindic> que vai <vbfutir> levar <vbact> um tempo para eu <prn1sngsubj> melhorar <vb1> <vbact> melhorar <vbinf>. Nenhuma <prnqtf> área da minha <prnposs> vida anda <vbact> bem <advemph> <advints> <advmanner>.

– Mas que pessimismo é esse?

– Não é pessimismo. Se eu <prn1sngsubj> tivesse <vb1> ouvido <vbment> <vbpriv> a minha <prnposs> mãe hoje <advtime> eu <prn1sngsubj> não <advnao> estaria <vb1> assim

<advmanner>.

As amostras abaixo ilustram a presença de características linguísticas do polo negativo dessa dimensão em bulas de remédio e licitações.

Bulas de remédio:

Os <artdef> comprimidos apresentam dois sulcos para <prpall> facilitar a <artdef> composição <nabst> <ncomp> de <prpall> doses. Indicações <nabst> : xxxx⁹ é um glicocorticóide <ncomp> de <prpall> uso <adjattr> oral <adjtopi>, indicado <vbpastprt> para <prpall> tratamento <nabst> de <prpall> diversas <adjattr> <adjrela> patologias <nabst>, tais como <prpall> : Reumatologia : artrite reumatóide <adjattr>, lupus eritematoso <adjattr> sistêmico <adjattr> (...).

Licitações:

A <artdef> União, por <prpall> intermédio do <prpall> <artdef> Instituto Nacional de Câncer José Alencar Gomes da Silva (Inca) do <prpall> <artdef> Ministério da <prpall> <artdef> Saúde <ncomp>, através do <prpall> <artdef> Serviço de <prpall> Compras <ncomp>, torna público para <prpall> conhecimento <nabst> dos <prpall> <artdef> interessados que na <prpall> <artdef> data, horário e local <adjrela> abaixo indicados <vbpastprt>, fará realizar a <artdef> Cotação Eletrônica, para <prpall> aquisição <nabst> do <prpall> <artdef> objeto descrito <vbpastprt> no <prpall> <artdef> item xxxx.

4.1.2. Dimensão 2: Argumentação

Essa dimensão possui características linguísticas ligadas à argumentação, em maior presença no polo positivo. Assim como em Biber (1995, p. 224), entendemos argumentação nesta instância como 'apresentação qualificada de informação, considerando diversas possibilidades diferentes'¹⁰. Os diversos tipos de oração subordinada complementam o verbo e assim colaboram para explicitar os sentidos pretendidos. Segundo Biber (1995, p. 161), 'orações condicionais e infinitivos podem funcionar como parte do (...) esquema geral de

⁹ Esse símbolo indica a anonimização de informação com a finalidade de resguardar os participantes mencionados nos textos.

¹⁰ 'The term argumentative is used to refer to a qualified presentation of information, considering a number of different possibilities.'

argumentação¹¹. As orações relativas elaboram a referência a um elemento do discurso, também servindo para qualificar a informação apresentada. Os atenuadores colaboram na qualificação da informação, tornando-a menos determinada e portanto menos vulnerável. Os comparativos e quantificadores permitem o manuseio da informação de acordo com os propósitos dos interlocutores. As demais características trabalham nesse sentido, de agregar recursos à qualificação da informação apresentada.

Tabela 11: Características linguísticas Dimensão 2 (polo único)

Característica		Variável	Peso
Oração	Subordinada com 'que' controlada por substantivo	nounque	0.593
Pronome	'Que' como pronome relativo	prnque	0.529
Advérbio	Comparativos	advcomp	0.473
Substantivo	De cognição	ncogn	0.451
Oração	Subordinada com 'que' ou reduzida de infinitivo controlada por substantivo (posicionamento)	nqueinfcl	0.447
Oração	Reduzida de infinitivo controlada por adjetivo	clinfadj	0.447
Oração	Subordinada com 'que' controlada por preposição	clqueeprp	0.426
Pronome	Demonstrativos	prndem	0.406
Oração	Reduzida de infinitivo controlada por preposição	clinfprp	0.395
Oração	Subordinada com 'que' controlada por adjetivo (posicionamento)	adjque	0.378
Oração	Reduzida de infinitivo controlada por adjetivo de facilidade ou dificuldade	clinfadjease	0.334
Advérbio	Atenuadores	advhedg	0.331

¹¹ 'Conditional clauses and infinitives can function as part of the same overall scheme of argumentation.'

Artigo	Indefinidos	artindef	0.325
Verbo	Futuro do passado	vbfutpret	0.311
Conjunção	Coordenada (adversativas)	cjadv	0.31
(Pronome	Quantificadores	prnqtf	0.352)
(Adjetivo	Em posição predicativa	adjpred	0.353)
(Modal	Poder	mdpoder	0.336)
(Pronome	Oblíquo de terceira pessoa	prn3obl	0.343)

A distribuição dos escores médios de cada registro nessa dimensão aparece na Figura 4.




Figura 4: Escores médios dos registros na dimensão 2

Dentre os registros com maior escore, aparecem muitos considerados naturalmente argumentativos, como discursos políticos, entrevistas, editoriais e sessões do congresso. Ao mesmo tempo, o registro com maior escore médio é o horóscopo, que não é automaticamente associado a essa dimensão, mas que possui grande concentração das características linguísticas próprias da dimensão argumentativa, conforme mostra o exemplo mais abaixo. O horóscopo, na verdade, visa a fazer previsões acerca do futuro e a convencer o consulente de sua veracidade, o que constitui um tipo de argumentação, mesmo que não do tipo clássico, com dos debates ou editoriais. Na posição inferior da escala estão, por sua vez, os registros com pouca ou nenhuma carga argumentativa, como websites, leis e normas, receitas e bulas de remédio, em que a veracidade ou plausibilidade da informação não precisa ser discutida, mas apenas atestada.

As amostras abaixo ilustram a presença das características linguísticas dessa dimensão em horóscopos e discursos políticos.

Horóscopos:

Siga a trilha <nounque> que <prnque> seus sentimentos <ncogn> propuserem hoje. Permita-se a surpresa, deixe de lado todos os planejamentos <nounque> que <prnque> tiver feito para este <prndem> dia e observe a direção <nounque> que <prnque> seus sentimentos <ncogn> mais <advcomp> íntimos estabelecerem. Conversas sérias podem e devem ser desenvolvidas, mas <cjadv> antes de tudo você deve tirar de cima de essas <prndem> o ar de gravidade, pois sem isso <prndem> só encontrará resistência (...).

Discursos políticos:

Este <prndem> país chama-se Brasil. Tem um <artindef> potencial extraordinário de crescimento, de tecnologia e, sobretudo, tem um <artindef> povo excepcional. Não somos os melhores <advcomp> do mundo, mas <cjadv> duvido que tenha, no mundo, melhores <advcomp> do que nós. No máximo, haverá um <artindef> empate. Não poderiam <vbftpret> os organizadores deste <prndem> evento ser mais <advcomp> felizes do que foram <advcomp>.

4.1.3. Dimensão 3: Oralidade versus letramento

Esta dimensão baseia-se na distinção entre oral e letrado, conceitos que Biber (1995, p.238) entende como: 'o termo 'oral' refere-se ao discurso estereotipicamente falado – isto é, conversação – enquanto o termo 'letrado' refere-se ao discurso estereotipicamente escrito – isto é, exposição informacional.'¹² O polo positivo da dimensão reflete a oralidade, ao passo que o negativo, o letramento.

As características linguísticas associadas à oralidade indicam aspectos relacionados à conversação e à informalidade, como contrações, interrogativas diretas (sem advérbio interrogativo), questões 'tag' (colocadas ao final de uma locução), marcadores discursivos da fala, conjunções coordenadas (que concatenam a informação, sem marcar proeminência via subordinação, que é um recurso da fala planejada ou da escrita), o modal 'ter que/de' (que confere uma certa informalidade ao discurso, em lugar de 'deve', que seria mais formal),

¹² 'The term oral refers to stereotypically spoken discourse - that is, conversation - while the term literate refers to stereotypically written discourse - that is, informational exposition.'

advérbio de lugar e pronomes demonstrativos (dêiticos que refletem o local físico do discurso¹³).

Tabela 12: Características linguísticas do polo positivo da Dimensão 3

Característica		Variável	Peso
Interrogativa	Questões 'tag'	qsttag	0.795
Outros	Contrações	contrac	0.714
Outros	Marcadores discursivos	discmrkr	0.671
Interrogativa	Sem advérbio interrogativo	qsyn	0.547
Pronome	Terceira pessoa do singular, em posição de sujeito	prn3sngsubj	0.498
Pronome	Terceira pessoa do plural, em posição de sujeito	prn3plusubj	0.481
Conjunção	Coordenada (conclusivas)	cjcncl	0.475
Advérbio	De lugar	advpl	0.462
Modal	Ter que/de	mdter	0.315
(Oração	Subordinada com 'que', controlada por verbo no modo indicativo	vbqueindic	0.316)
(Pronome	Demonstrativo	prndem	0.362)

As características linguísticas associadas ao letramento, por sua vez, remetem a características da exposição escrita. Primeiramente, estão em menor número ou simplesmente ausentes as características relacionadas à oralidade, o que já confere ao discurso um maior grau de formalidade, informação e distanciamento. Além disso, as características presentes no polo negativo conspiram para tornar o discurso ainda mais denso, expositivo e distante do leitor/ouvinte, tais como a alta densidade lexical, medida pela razão forma-ocorrência, que sugere o capacidade, por parte dos interlocutores, de lidar com uma grande quantidade de

¹³ 'time and place deictics reflect the actual temporal and physical setting of discourse' (Biber 1995, p.136)

vocabulário, por um lado, e a apresentação de mais informação em menor espaço, e adjetivos pré-modificadores, em posição atributiva, que são uma opção típica do discurso planejado, formal.

Tabela 13 Características linguísticas do polo negativo da Dimensão 3

Característica		Variável	Peso
Contagens de palavras	Razão forma-ocorrência	ttr	-0.346
Adjetivo	Em posição atributiva, pré-modificador	adjpre	-0.357
(Pronome	Possessivos	prnposs	-0.431)

A distribuição dos escores médios de cada registro nessa dimensão aparece na Figura 5.




Figura 5: Escores médios dos registros na dimensão 3

Os cinco registros com maior escore no polo positivo são todos falados, destacando-se, pela magnitude dos escores, as entrevistas sociolinguísticas e a conversação face a face. Esses dois registros estão praticamente empatados, em termos de escore médio, e bastante distantes dos demais. Isso corrobora a noção de oralidade apresentada acima, como refletindo uma mescla de características associadas à conversação. Percebe-se a presença de registros que simulam a conversação face a face nos meios de comunicação, como as entrevistas e novelas de TV e os programas de rádio. Além disso, há registros que tentam recriar a conversação, por meio de diálogos construídos e reproduzidos na escrita, como os quadrinhos, a literatura de ficção e as piadas. Os registros mais letrados, por sua vez, compreendem aqueles com maior carga expositiva, como rótulos de embalagem, receitas culinárias e cartas de negócio. Entretanto, como se pode ver na magnitude dos escores médios, há muita proximidade entre os registros na

base da escala, indicando pouca diferenciação entre os escores.

As amostras abaixo ilustram a presença das características linguísticas relativas à oralidade em entrevistas sociolinguísticas e conversação.

Entrevistas sociolinguísticas:

- Então <discmrkr>, o que que chocou na morte de Ayrton Senna, né <contrac> <qsttag>?
- É , de repente, corrida, corrida pra mim seria o Ayrton Senna, né <contrac> <qsttag>? Então <discmrkr>, ligava- se a televisão pra assistir não a corrida propriamente dita, mas, de repente, pra ver alguém da gente, né <contrac> <qsttag>? Brasileiro empunhando a bandeira lá <advpl>.

Conversação:

- Eu tinha largado porque ele <prn3sngsubj> tinha me dado um couro, né <contrac> <qsttag>? Aí <discmrkr>, eu chamei as polícia. Não teve ocorrência nem nada. As polícia [sic] deixou ele em casa. Aí <discmrkr>, eu andei e consegui tirar ele. Aí <discmrkr> a tutelar tirou, porque eu tenho uma menina deficiente, né <contrac> <qsttag>?
- Sei.
- Aí <discmrkr>, ele <prn3sngsubj> foi para casa da mãe dele. Agora <discmrkr>, ele <prn3sngsubj> brigou lá <advpl> porque ele <prn3sngsubj> fuma e bebe e se droga.

As amostras abaixo ilustram a presença das características linguísticas relativas ao letramento em rótulos e receitas culinárias.

Rótulos de produtos:

xxxx é um soro concentrado anti-fadiga, com extratos de brócolis, soja e outros ingredientes naturais. Este soro com 97.5% de ingredientes naturais ajuda a potencializar o funcionamento da mitocôndria e produção de energia celular, reduzindo a fadiga de a pele antes que vire sinal de envelhecimento. xxx 30ml é o cuidado altamente concentrado que proporciona excepcionais <adjpre> resultados antienvelhecimento.

Este texto completo tem uma razão forma-ocorrência de 2,105, acima da média de 1,94 do *corpus* como um todo.

4.1.4. Dimensão 4: Discurso procedural

Esta dimensão possui apenas um polo, contendo características linguísticas ligadas à apresentação de procedimentos. Os verbos no subjuntivo presente e imperativo indicam a necessidade, por parte do interlocutor, de seguir instruções, expressas com omissão de sujeito. Essas ações estão muitas vezes relacionadas a objetos, ingredientes e artefatos denotados pelos substantivos concretos. Os verbos de facilitação mostram que essas instruções podem ser possibilitadas ou permitidas por meio de determinadas ações. As coordenadas oracionais concatenam essas ações em sequência, sem hierarquizá-las, mas enfatizando a ordem dos procedimentos. Os advérbios de modo, por sua vez, qualificam as ações em termos da maneira pela qual devem ser conduzidas.

Tabela 14: Características linguísticas do polo positivo da Dimensão 4 (polo único)

Característica		Variável	Peso
Verbo	Presente do subjuntivo	vbsubpres	0.821
Verbo	Imperativo	vbimp	0.774
Substantivo	Concretos	nconc	0.565
Outros	Omissão de sujeito	subjdrop	0.545
Verbo	De facilitação	vbfacil	0.485
Conjunção	Coordenada (oracionais)	cjcoorcls	0.465
(Advérbio	Modo	advmanner	0.345)

A distribuição dos escores médios de cada registro nessa dimensão aparece na Figura 6.




Figura 6: Escores médios dos registros na dimensão 4

Nessa dimensão há uma distância entre receitas e os demais registros, sugerindo que o discurso procedural é muito mais característico das receitas do que dos demais registros. Mesmo assim, há marcas de apresentação de procedimentos em outros registros como instruções de jogos, horóscopos, liturgia da missa e rótulos de embalagem, todos reconhecidamente procedurais. As canções surgem como uma surpresa, pois não são tidas como exemplos típicos dessa dimensão. Os registros menos procedurais incluem atas, artigos acadêmicos e reportagens.

As amostras abaixo ilustram a presença das características linguísticas dessa dimensão em receitas e instruções de jogos.

Receitas:

Caipirinha

1 limão-galego <nconc>

1 colher <nconc> (sopa) de açúcar <nconc>

2 cubos <nconc> de gelo <nconc> triturados

4 colheres <nconc> (sopa) de pinga <nconc>

Modo de Preparo : Lave <vbimp> <subjdrop> o limão <nconc>, corte <vbimp> <subjdrop> em quatro pedaços <nconc>. Retire <vbimp> <subjdrop> a parte branca interna. Coloque <vbimp> <subjdrop> em um copo <nconc> baixo e largo, junte <vbimp> <subjdrop> açúcar <nconc> e, com um socador <nconc>, amasse <vbimp> <subjdrop> até liberar todo o suco <nconc>. Acrescente <subjdrop> <vbimp> gelo <nconc> triturado, pinga <nconc>, misture <subjdrop> <vbimp> bem e <cjcoorcls> sirva <subjdrop> <vbimp>.

4.1.5. Dimensão 5: Orientação temporal para o futuro *versus* orientação temporal para o passado

As características linguísticas do polo positivo desta dimensão indicam uma orientação temporal para o futuro, marcada por verbos no futuro do subjuntivo e no futuro do presente do indicativo, além de advérbios de probabilidade, que refletem a expectativa de ocorrência dos processos verbais. Os modais ‘dever’ e ‘poder’ também sugerem possibilidade, na medida em que são usados para indicar estados e ações hipotéticas no futuro. As conjunções coordenadas usadas para ligar tanto orações quanto sintagmas podem representar as opções de ocorrência no futuro. Os adjetivos relacionais qualificam os nomes usados com os verbos.

Tabela 15: Características linguísticas do polo positivo da Dimensão 5

Características		Variável	Peso
Verbo	Futuro do subjuntivo	vbsubfut	0.616
Conjunção	Coordenada (ou)	cjou	0.611
Verbo	Futuro do presente do indicativo	vbfutpres	0.513
Modal	Dever	mddever	0.474

Modal	Poder	mdpoder	0.426
Oração	Coordenada (condicionais)	cjcond	0.39
Advérbio	De probabilidade	advliki	0.389
Conjunção	Coordenada (frasais)	cjcoorphr	0.322
(Adjetivo	Relacional	adjrela	0.303)

As características linguísticas do polo negativo também marcam a temporalidade, porém em relação ao passado. Há confluência de três tempos verbais, sendo dois do modo indicativo (pretérito perfeito e imperfeito) e um do subjuntivo (pretérito). Os substantivos de lugar refletem os tópicos tratados, assim como os adjetivos afiliativos/pátrios.

Tabela 16: Características linguísticas do polo negativo da Dimensão 5

Característica		Variável	Peso
Substantivo	De lugar	nplac	-0.301
Verbo	Pretérito do subjuntivo	vbsubpast	-0.308
Adjetivo	Afiliativo	adjaffi	-0.355
Verbo	Pretérito imperfeito	vbimprf	-0.375
Verbo	Pretérito do indicativo	vbpast	-0.554
(Artigo	Indefinidos	artindef	-0.32)

A distribuição dos escores médios de cada registro nessa dimensão aparece na Figura 7.




Figura 7: Escores médios dos registros na dimensão 5

Os registros com orientação temporal mais marcada para o futuro são as licitações, instruções de jogos e horóscopos. Os dois primeiros estabelecem condições para ações futuras, enquanto o último tenta prever o futuro. Na base da escala estão os registros com maior inclinação para a temporalidade voltada ao passado. Aparecem aí essencialmente a ficção literária, nos seus vários tipos, e a reportagem, do jornal, revista e TV.

As amostras abaixo ilustram a presença das características linguísticas relativas à orientação temporal para o futuro em licitações e instruções de jogos.

Licitações:

A proponente que chegar <vbsubfut> atrasada será <vbfutpres> desclassificada. Fica, desde logo, vedado o uso de equipamento de telefonia móvel durante a(s) sessão(ões) de abertura. Fundamento legal e tipo de licitação. A presente licitação reger-se-á <vbfutpres> pelas normas e procedimentos <cjcoorphr> do Regulamento Interno de Licitações e Contratos do xxxx, e pelo presente instrumento convocatório. Tipo de Licitação: menor preço. Participação: Poderão <vbfutpres> <mdpoder> participar desta licitação empresas que comprovem estar devidamente regularizadas perante os órgãos públicos competentes, autorizados pelos mesmos a comercializar os equipamentos objeto de este edital. Não poderão <mdpoder> <vbfutpres> participar da presente licitação: Empresas suspensas de licitar ou <cjou> contratar com o xxxx, ou <cjou> que estejam litigando administrativa ou <cjou> judicialmente contra o xxxx.

Instruções de jogos:

O competidor que causar <vbsubfut> o pinote estará <vbfutpres> desclassificado. O burrinho será <vbfutpres> então rearmado para o prosseguimento do jogo. Se a sela estiver <vbsubfut> fora de posição, caberá <vbfutpres> ao competidor seguinte ajustá-la. Vence a partida quem permanecer <vbsubfut> em jogo depois que os demais forem <vbsubfut> desclassificados.

As amostras abaixo ilustram a presença das características linguísticas relativas à orientação temporal para o passado em ficção para jovens e contos.

Ficção para jovens:

A Marcella vivia <vbimprf> me protegendo, desde pequeno. Talvez porque, quando eu era <vbimprf> bem criança, tive <vbpast> bronquite alérgica. Nem lembro bem como era <vbimprf>, mas dizem que eu tossia <vbimprf> tanto que até tinham <vbimprf> medo de que eu botasse <vbsubpast> o pulmão pra fora. Desde então, ela cuidava <vbimprf> de mim. Sempre me ajudava <vbimprf> nos trabalhos da escola.

Contos:

Estava <vbimprf> mais velha, viu <vbpast> ao entrar. E mais amarga, percebeu <vbpast> depois. Tu não avisou <vbpast> que vinha <vbimprf> ela, resmungou <vbpast> no seu velho jeito azedo, que antigamente ele não compreendia <vbimprf>. Mas agora, tantos anos depois, aprendera a traduzir como que-saudade, seja-bem-vindo, que-bom-ver-você ou qualquer coisa assim. Mais carinhosa, embora inábil. Abraçou- <vbpast> a, desajeitado.

4.1.6. Dimensão 6: Discurso relatado

As características linguísticas desta dimensão indicam presença marcante do discurso indireto.

Os verbos públicos denotam preferência pelo relato de ações verbais como dizer, contar e narrar, muitos dos quais ocorrem na segunda pessoa. Os pronomes oblíquos e possessivos refletem os participantes do discurso relatado. As orações coordenadas finais sugerem tomada de conclusão. O modal 'haver de/que', bem como os pronomes oblíquos incomuns, sugerem escolhas linguísticas menos usuais. As orações subordinadas mostram detalhamento da informação e as orações relativas, detalhamento da referência.

Tabela 17: Características linguísticas do polo positivo da Dimensão 6

Característica		Variável	Peso
Pronome	Oblíquo menos comum	objprnrare	0.628
Verbo	Segunda pessoa	vb2	0.466
Oração	Coordenada (finais)	cjfinal	0.413
Pronome	Oblíquo de terceira pessoa	prn3obl	0.371
Verbo	Públicos	vbpubl	0.327
Modal	Haver que/de	mdhaver	0.311
(Pronome	Possessivos	prnpos	0.424)
(Oração	Subordinada com 'que' controlada por substantivo	nounque	0.308)
(Pronome	'Que' como pronome relativo	prnque	0.34)
(Oração	Subordinada com 'que' controlada por preposição	clqueeprp	0.38)

As características linguísticas do polo negativo estão todas presentes com maior peso em outros fatores, não sendo, portanto, constitutivas desta dimensão. Dessa forma, não servem como contraponto direto às características discursivas do polo positivo e por isso não são incluídas como um polo verdadeiro na interpretação da dimensão.

(Adjetivo	Avaliativo	adjeval	-0.318)
(Advérbio	Amplificadores	advampl	-0.34)

(Advérbio	De intensidade	advints	-0.341)
(Interrogativa	Sem advérbio interrogativo	qsyn	-0.33)

A distribuição dos escores médios de cada registro nessa dimensão aparece na Figura 8.




Figura 8: Escores médios dos registros na dimensão 6

Os registros mais característicos dessa dimensão são principalmente formas de discurso literário, como contos, ficção para jovens e geral, novelas de TV e piadas. Todos esses trazem discurso indireto. O registro com maior escore médio, a liturgia da missa, além do constante uso do discurso indireto para referenciar os eventos das Escrituras Sagradas e de verbos na

segunda pessoa, apresenta formas pronominais pouco usuais, como 'vos' e 'convosco', resultando assim nos escores mais altos nessa dimensão.

As amostras abaixo ilustram a presença das características linguísticas dessa dimensão na liturgia da missa e nos contos.

Liturgia da missa:

Vigiai <vb2>, vigiai <vb2>, eu vos <objprnrare> digo <vbpubl>, não sabeis <vb2> nem o dia, nem a hora. Vigiai <vb2>, vigiai <vb2>, eu repito <vbpubl>, eis que vem <vb2> o Senhor em sua glória! Foste <vb2> amigo, antigamente, desta terra que amaste <vb2>, deste povo que escolheste <vb2>; sua sorte melhoraste <vb2>, perdoaste <vb2>, perdoaste <vbpubl> seus pecados, tua raiva acalmaste <vb2>.

Contos:

Meus colegas responderam <vbpubl> que a sociedade era secreta, que de certa forma ela já nascia (isso foi dito <vbpubl> ironicamente) desmoralizada, e que seu nome não teria a menor importância, pois não seria divulgado <vbpubl>. Acrescentaram <vbpubl> que a maçonaria e o rosa-cruzismo tinham originalmente títulos bonitos e respeitáveis objetivos filantrópicos (...).

4.2. Avaliação das dimensões

As dimensões podem ser avaliadas de dois modos: para saber se há diferenças significativas entre os escores médios dos registros e para verificar a quantidade de variação entre os registros capturada pelas dimensões. Em ambos os casos, usa-se os escores médios de cada registro em cada dimensão. Para saber se há diferenças significativas entre eles, emprega-se a prova ANOVA (teste F)¹⁴, e para descobrir o percentual de variação apreendida em cada dimensão, usa-se a estatística R². Esses valores aparecem na Tabela 18.

Tabela 18: ANOVA e R²

Dimensão	F	p	gl	R ²
1	97,037	0,000	46	83,3%

¹⁴ 'ANOVA, which tests whether there are statistically significant differences among the mean scores for the registers with respect to the dimension scores.' (Biber e Conrad 2009, p. 229)

2	19,926	0,000	46	48,1%
3	101,521	0,000	46	83,9%
4	57,961	0,000	46	73,5%
5	40,561	0,000	46	67,6%
6	43,525	0,000	46	69,2%

Os resultados da prova ANOVA são todos significativos (coluna p), o que indica que há diferenças reais entre os registros em cada dimensão. Isso mostra que as dimensões conseguem distinguir os registros, sendo desse modo parâmetros estatisticamente confiáveis da variação entre registros do português brasileiro. O valor de R^2 não é uma prova estatística e desse modo não se pode dizer se é estatisticamente significativo. Ele mede, de fato, 'a porcentagem de variação entre os escores médios que podem ser previstos a partir das categorias representadas pelos registros' (Biber & Conrad, 2009, p. 229)¹⁵. A porcentagem de variação indicada pelo R^2 em cinco das seis dimensões é maior do que 50%, mostrando que as dimensões respondem pela maioria da variação entre os registros. Em dois casos, ela está acima de 80%, o que é um índice alto, em comparação com outras pesquisas multidimensionais para as quais essa informação está disponível. A Tabela 19 traz os valores médios de R^2 para estudos multidimensionais de variação de registro de outras línguas. Como se nota, o valor médio obtido neste estudo é superior aos das outras línguas comparadas. Isso reforça a ideia de que a quantidade de variação entre os registros do português brasileiro alcançada nesta pesquisa é alta para os padrões da abordagem multidimensional.

Tabela 19: Valores médios de R^2 de estudos multidimensionais

Língua	Dimensões	R^2 médio
Tuvaluan	3	46%
Coreano	6	18%

¹⁵ 'The r^2 value measures the percentage of the variance among dimension scores that can be predicted by knowing the register categories.'

Somali	6	67%
Inglês	5	56%
Português brasileiro	6	71%

5 Conclusão

O presente projeto teve como objetivo principal descobrir as dimensões de variação de registro do português brasileiro usando a abordagem da Linguística de *Corpus* conhecida como Análise Multidimensional (Berber Sardinha, 2000, 2004, no prelo; Berber Sardinha & Ferreira, em prep.; Berber Sardinha & Veirano Pinto, em prep.; Biber, 1988; Conrad & Biber, 2001) (Biber, 1995; Reppen, Fitzmaurice, & Biber, 2002). Este objetivo foi cumprido; foram descobertas seis dimensões, a saber:

1. Produção com envolvimento *versus* produção com foco informacional
2. Argumentação
3. Oralidade *versus* letramento
4. Discurso procedural
5. Orientação temporal para o futuro *versus* orientação temporal para o passado
6. Discurso relatado

Essas dimensões respondem pela maior parte da variação existente entre os textos (até 83%). Em comparação a outras variedades linguísticas nacionais já pesquisadas com essa abordagem, pode-se fazer as seguintes considerações. A dimensão 1 (produção envolvida *versus* informacional) está presente, de alguma forma, em todas as línguas pesquisadas até o momento. A dimensão 2 (argumentação) ocorre no inglês na dimensão 4 (inicialmente chamada de persuasão mas depois alterada para argumentação) (Biber, 1988, 2009) e no somali nas dimensões 3 e 6 (Biber & Hared, 1994). A dimensão 3 (oralidade *versus* letramento) aparece no espanhol (Biber & Tracy-Ventura, 2007), dimensão 1. A dimensão 4 (discurso procedural) não aparece em outros estudos de variedades nacionais, mas sim no estudo relativo à linguagem universitária (Biber, 2006), dimensão 2, e a de *call centers* (Friginal, 2009), dimensão 2. A dimensão 5 (orientação temporal) surge no somali (dimensão 4 -- Biber & Hared, 1994), coreano

(dimensão 4 -- Kim & Biber, 1994), espanhol (dimensão 3 -- Biber & Tracy-Ventura, 2007) e inglês (dimensão 2 -- Biber, 1988). Por fim, a dimensão 6 (discurso relatado) desponta no coreano (dimensão 5 -- Kim & Biber, 1994), somali (dimensão 3 -- Biber & Hared, 1994), espanhol (dimensão 5 -- Biber & Tracy-Ventura, 2007), e na análise piloto do inglês (Biber, 1986) na dimensão 3 (*'Reported versus immediate style'*)

Os objetivos específicos também foram cumpridos, a saber:

1. Foram determinadas as variáveis relevantes para descrição da variação textual do português brasileiro.
2. Variáveis colocacionais não se mostraram adequadas para inclusão nesta pesquisa porque tendem a se isolar das morfológicas, lexicais, sintáticas e semânticas.
3. Foram identificados os fatores estatísticos responsáveis pela variação textual do português brasileiro, bem como a parcela de variação correspondente a cada fator.
4. Foi feita a interpretação dos fatores por meio de critérios discursivos e funcionais.
5. Está sendo disponibilizado na *web* material de apoio para a realização de AMD do português, visando à divulgação da área, no endereço <http://corpuslg.org/gelc/gelc.php>.

6 Produção

6.1. Artigos

1. BERBER SARDINHA, Tony (2010) Abordagem metodológica da Análise Multidimensional. *Gragoatá*, 29, 107-125.
2. BERBER SARDINHA, Tony, KAUFFMANN, Carlos, ACUNZO, Cristina. M. (em prep.) Dimensions of register variation in Brazilian Portuguese. *Corpora*.

6.2. Livros e capítulos

1. BERBER SARDINHA, Tony e FERREIRA, Telma. (em preparação) (Orgs.) *Working with Portuguese Corpora*. Londres: Bloomsbury/Continuum.
2. BERBER SARDINHA, Tony, KAUFFMANN, Carlos, ACUNZO, Cristina. M. Register Variation in Brazilian Portuguese. In BERBER SARDINHA, Tony e FERREIRA, Telma. (em preparação) (Orgs.) *Working with Portuguese Corpora*. Londres:

Bloomsbury/Continuum.

3. BERBER SARDINHA, Tony e VEIRANO PINTO, Márcia. (em preparação) (Orgs.) *Multidimensional Analysis 25 Years On: A Tribute to Douglas Biber*. Amsterdã/Filadélfia: John Benjamins.
4. BERBER SARDINHA, Tony, KAUFFMANN, Carlos, ACUNZO, Cristina. M. Dimensions of Variation in Brazilian Portuguese. In BERBER SARDINHA, Tony e VEIRANO PINTO, Márcia. (em preparação) (Orgs.) *Multidimensional Analysis 25 Years On: A Tribute to Douglas Biber*. Amsterdã/Filadélfia: John Benjamins.
5. BERBER SARDINHA, Tony. (no prelo). Variação de registros na Internet. In T. M. G. Shepherd & T. Salies (Orgs.), *Linguística da Internet*. São Paulo, SP: Contexto.

6.3. Palestras, comunicações, mesas-redondas, oficinas, seminários

1. BERBER SARDINHA, Tony An introduction to Multi-Dimensional Analysis. 2012. (Conferência ou palestra, Apresentação de Trabalho) Referências adicionais : França/Inglês. Meio de divulgação: Impresso; Local: Université Paris 7 Diderot; Cidade: Paris, França; Evento: Talk - Centre de Ressources en Langues; Inst.promotora/financiadora: Université Paris 7 Diderot
2. BERBER SARDINHA, Tony, KAUFFMANN, Carlos, ACUNZO, Cristina. M. Dimensions of Variation in Brazilian Portuguese. 2012. (Comunicação, Apresentação de Trabalho) Referências adicionais : Nova Zelândia/Inglês. Meio de divulgação: Impresso; Local: University of Auckland; Cidade: Auckland, Nova Zelândia; Evento: I Asia Pacific Corpus Linguistics Conference; Inst.promotora/financiadora: University of Auckland
3. BERBER SARDINHA, Tony Register Variation in Brazilian Portuguese. 2012. (Conferência ou palestra, Apresentação de Trabalho) Referências adicionais : Estados Unidos/Inglês. Meio de divulgação: Impresso; Local: Northern Arizona University; Cidade: Flagstaff, AZ; Evento: Visiting Professor Talk; Inst.promotora/financiadora: Northern Arizona University
4. BERBER SARDINHA, Tony Workshop: Linguística de Corpus. 2012. (Outra, Apresentação de Trabalho) Referências adicionais : Brasil/Português. Meio de divulgação: Impresso; Local: UERJ; Cidade: Rio de Janeiro, RJ; Evento: XI Fórum de Estudos Linguísticos da UERJ; Inst.promotora/financiadora: UERJ.
5. BERBER SARDINHA, Tony Questões Atuais da Linguística de Corpus. 2012.

- (Conferência ou palestra, Apresentação de Trabalho). Referências adicionais : Brasil/Português. Meio de divulgação: Impresso; Local: PUCRS; Cidade: Porto Alegre, RS; Evento: Palestra; Inst.promotora/financiadora: PUCRS.
6. BERBER SARDINHA, Tony Register variation and translation. 2012. (Workshop, Apresentação de Trabalho). Referências adicionais : Brasil/Português. Meio de divulgação: Impresso; Local: PUCRS; Cidade: Porto Alegre, RS; Evento: Workshop; Inst.promotora/financiadora: PUCRS.
6. BERBER SARDINHA, Tony A Linguística de Corpus dos Brasileiros. 2011. (Outra, Apresentação de Trabalho) Referências adicionais : Brasil/Português. Meio de divulgação: Impresso; Local: UFMG; Cidade: Belo Horizonte, MG; Evento: X Encontro de Linguística de Corpus; Inst.promotora/financiadora: UFMG
7. BERBER SARDINHA, Tony Buscando dimensões de variação no português brasileiro. 2011. (Conferência ou palestra, Apresentação de Trabalho). Referências adicionais : Brasil/Português. Meio de divulgação: Impresso; Local: UFRN; Cidade: Natal, RN; Evento: II Seminário de Pesquisa Grupo de Estudos Discurso & Gramática; Inst.promotora/financiadora: UFRN
8. BERBER SARDINHA, Tony, KAUFFMANN, Carlos, ACUNZO, Cristina. M. Dimensions of Variation in Brazilian Portuguese. 2011. (Comunicação, Apresentação de Trabalho). Referências adicionais : Estados Unidos/Inglês. Meio de divulgação: Impresso; Local: Georgia State University; Cidade: Atlanta, GA; Evento: American Association for Corpus Linguistics Conference (AACL) 2011; Inst.promotora/financiadora: Georgia State University.
9. BERBER SARDINHA, Tony, KAUFFMANN, Carlos, ACUNZO, Cristina. M. Dimensions of Variation in Brazilian Portuguese. 2011. (Comunicação, Apresentação de Trabalho). Referências adicionais : Grã-Bretanha/Inglês. Meio de divulgação: Outro; Local: ICC; Cidade: Birmingham, UK; Evento: 6th International Corpus Linguistics Conference; Inst.promotora/financiadora: University of Birmingham.
10. BERBER SARDINHA, Tony, KAUFFMANN, Carlos, ACUNZO, Cristina. M. Dimensions of Variation in Brazilian Portuguese. 2011. (Comunicação, Apresentação de Trabalho). Referências adicionais : Brasil/Inglês. Meio de divulgação: Impresso; Local: UFMG; Cidade: Belo Horizonte, MG; Evento: X Encontro de Linguística de Corpus; Inst.promotora/financiadora: UFMG

11. BERBER SARDINHA, Tony Dimensions of Variation in Spoken Brazilian Portuguese. 2011. (Comunicação, Apresentação de Trabalho). Referências adicionais : Brasil/Inglês. Meio de divulgação: Impresso; Local: UFMG; Cidade: Belo Horizonte; Evento: GSCP 2012; Inst.promotora/financiadora: UFMG.
12. BERBER SARDINHA, Tony, VEIRANO, M. V., ACUNZO, Cristina. M., SOUZA, Renata Condi de, KAUFFMANN, Carlos, DUTRA, P. B., DELEGA, D. Recent perspectives on Multi-Dimensional Analysis. 2011. (Simpósio, Apresentação de Trabalho). Referências adicionais : Grã-Bretanha/Inglês. Meio de divulgação: Outro; Local: ICC; Cidade: Birmingham, UK; Evento: 6th International Corpus Linguistics Conference; Inst.promotora/financiadora: University of Birmingham.
13. BERBER SARDINHA, Tony, KAUFFMANN, Carlos, ACUNZO, Cristina. M. Workshop: An Introduction to Multi-Dimensional Analysis. 2011. (Outra, Apresentação de Trabalho) Referências adicionais : Brasil/Inglês. Meio de divulgação: Impresso; Local: UFMG; Cidade: Belo Horizonte, MG; Evento: X Encontro de Linguística de Corpus, V Escola Brasileira de Linguística Computacional; Inst.promotora/financiadora: UFMG.
14. BERBER SARDINHA, Tony Workshop: Ferramentas da Linguística de Corpus. 2011. (Outra, Apresentação de Trabalho). Referências adicionais : Brasil/Português. Meio de divulgação: Impresso; Local: UFRN; Cidade: Natal, RN; Evento: II Seminário de Pesquisa Grupo de Estudos Discurso & Gramática; Inst.promotora/financiadora: UFRN
15. BERBER SARDINHA, Tony Corpus Linguistics: Multi-Dimensional Analysis. 2010. (Seminário, Apresentação de Trabalho). Referências adicionais : Espanha/Inglês; Local: Universidade de Murcia; Cidade: Murcia, Espanha; Evento: Language Seminars; Inst.promotora/financiadora: Universidade de Murcia

7 Referências bibliográficas

- Baker, P. (2009). *Contemporary Corpus Linguistics*. London: Continuum.
- Berber Sardinha, T. (2000). Análise Multidimensional. *Delta*, 16(1), 99-127.
- Berber Sardinha, T. (2004). *Linguística de Corpus*. São Paulo: Manole.
- Berber Sardinha, T. (2009). *Pesquisa em Linguística de Corpus com WordSmith Tools*. Campinas: Mercado de Letras.
- Berber Sardinha, T. (no prelo). Perspectiva multidimensional de linguagens da Internet. In T. M. G. Shepherd & T. Salies (Eds.), *Linguística da Internet*. São Paulo, SP: Contexto.

- Berber Sardinha, T. (Ed.). (2005). *A Língua Portuguesa no Computador*. Campinas / São Paulo: Mercado de Letras / FAPESP.
- Berber Sardinha, T., & Ferreira, T. S. B. (Eds.). (em prep.). *Working with Portuguese Corpora*. Londres: Bloomsbury/Continuum.
- Berber Sardinha, T., & Veirano Pinto, M. (Eds.). (em prep.). *Multi-Dimensional Analysis, 25 years on: A Tribute to Douglas Biber*. Amsterdam/Philadelphia, PA: John Benjamins.
- Besnier, N. (1988). The linguistic relationships of spoken and written Nukulaelae registers. *Language*, 64, 707-736.
- Biber, D. (1985). Investigating macroscopic textual variation through multifeature/multidimensional analyses. *Linguistics*, 23, 337-360.
- Biber, D. (1986). Spoken and written textual dimension in English: Resolving the contradictory findings. *Language*, 62, 384-414.
- Biber, D. (1988). *Variation across Speech and Writing*. Cambridge: Cambridge University Press.
- Biber, D. (1990). Methodological issues regarding corpus-based analyses of linguistic variation. *Literary and Linguistic Computing*, 5(4), 257-269.
- Biber, D. (1995). *Dimensions of Register Variation - A Cross-Linguistic Comparison*. Cambridge: Cambridge University Press.
- Biber, D. (2006). *University Language: A Corpus-Based Study of Spoken and Written Registers*. Amsterdam/Philadelphia: John Benjamins.
- Biber, D. (2009). Multi-dimensional approaches. In A. Lüdeling & M. Kytö (Eds.), *Corpus Linguistics -- An International Handbook* (Vol. 2). Berlin / New York: Walter de Gruyter.
- Biber, D., & Conrad, S. (2009). *Register, genre, and style*. Cambridge ; New York: Cambridge University Press.
- Biber, D., Conrad, S., & Reppen, R. (1998). *Corpus Linguistics - Investigating Language Structure and Use*. Cambridge: Cambridge University Press.
- Biber, D., Davies, M., Jones, J. K., & Tracy-Ventura, N. (2006). Spoken and written register variation in Spanish: A multi-dimensional analysis. *Corpora*, 1(1), 1-37.
- Biber, D., & Hared, M. (1994). Linguistic correlates of the transition to literacy in Somali: Language adaptation in six press registers. In D. Biber & E. Finegan (Eds.), *Sociolinguistic Perspectives on Register* (pp. 182-216). Oxford: Oxford University Press.
- Biber, D., & Tracy-Ventura, N. (2007). Dimensions of register variation in Spanish. In G. Parodi (Ed.), *Working with Spanish Corpora* (pp. 54-89). London: Continuum.
- Bick, E. (2005). Gramática construtiva na análise automática da sintaxe portuguesa. In T. Berber Sardinha (Ed.), *A Língua Portuguesa no Computador* (pp. 91-112). Campinas: Mercado de Letras.
- Conrad, S., & Biber, D. (2001). *Variation in English: Multi-Dimensional Studies*. Harlow: Longman.

- Crossley, S., & Louwerse, M. M. (2007). Multi-dimensional register classification using bi-grams. *International Journal of Corpus Linguistics*, 12(4), 453-478.
- de Mönnink, I. M., Brom, N., & Oostdijk, N. H. J. (2003). Using the MF/MD method for automatic text classification. In S. Granger & S. Petch Tyson (Eds.), *Extending the scope of corpus based research : new applications new challenges* (pp. 15-25). Amsterdam: Rodopi.
- Friginal, E. (2009). *The language of outsourced call centers : a corpus-based study of cross-cultural interaction*. Amsterdam ; Philadelphia: John Benjamins Pub. Co.
- Kim, Y.-J., & Biber, D. (1994). A corpus-based analysis of register variation in Korean. In D. Biber & E. Finegan (Eds.), *Sociolinguistic Perspectives on Register* (pp. 157-181). Oxford: Oxford University Press.
- Lamb, W. (2008). *Scottish Gaelic speech and writing : register variation in an endangered language*. Belfast: Cló Ollscoil na Banríona.
- Lee, D. Y. W. (1999). *Modelling Variation in Spoken and Written Language: the Multi-Dimensional Approach Revisited*. Tese de doutoramento, Department of Linguistics and Modern English Language, Lancaster University, UK.
- Lüdeling, A., & Kytö, M. (2009). *Corpus Linguistics -- An International Handbook* (Vol. 2). Berlin / New York: Walter de Gruyter.
- McEnery, T., & Wilson, A. (1996). *Corpus Linguistics*. Edinburgh: Edinburgh University Press.
- Parodi, G. (2007). Variation across registers in Spanish: Exploring the El-Grial PUCV Corpus. In G. Parodi (Ed.), *Working with Spanish Corpora* (pp. 11-53). London: Continuum.
- Reppen, R., Fitzmaurice, S. M., & Biber, D. (2002). *Using corpora to explore linguistic variation*. Amsterdam ; Philadelphia: J. Benjamins.
- Sinclair, J. M. (1991). *Corpus, Concordance, Collocation*. Oxford, New York: Oxford University Press.
- Teubert, W., & Krishnamurthy, R. (Eds.). (2007). *Corpus Linguistics (Critical Concepts in Linguistics)* (Vol. 6). London: Routledge.

8 Anexos

8.1. Variáveis empregadas no estudo

1: <adjaffi> Adjetivo: Afiliativo/pátrio

2: <adjeval> Adjetivo: Avaliativo

3: <adjcolr> Adjetivo: De cor

- 4: <adjsize> Adjetivo: De tamanho
- 5: <adjattr> Adjetivo: Em posição atributiva
- 6: <adjpost> Adjetivo: Em posição atributiva, pós-modificador
- 7: <adjpre> Adjetivo: Em posição atributiva, pré-modificador
- 8: <adjpred> Adjetivo: Em posição predicativa
- 9: <adjexceval> Adjetivo: Exceto avaliativo
- 10: <adjrela> Adjetivo: Relacional
- 11: <adjsup> Adjetivo: Superlativos
- 12: <adjtime> Adjetivo: Temporal
- 13: <adjall> Adjetivo: Todos
- 14: <adjtopi> Adjetivo: Topical
- 15: <advampl> Advérbio: Amplificadores
- 16: <advhedg> Advérbio: Atenuadores
- 17: <advatt> Advérbio: Atitudinais
- 18: <advcomp> Advérbio: Comparativos
- 19: <advcmpd> Advérbio: Compostos
- 20: <advints> Advérbio: De intensidade
- 21: <advneg> Advérbio: De negação (exceto 'não')
- 22: <advlikl> Advérbio: De probabilidade
- 23: <advemph> Advérbio: Enfatizadores
- 24: <advother> Advérbio: Exceto de tempo, maneira ou lugar
- 25: <advfact> Advérbio: Factivos
- 26: <advlong> Advérbio: Longos (10 letras ou mais)
- 27: <advpl> Advérbio: Lugar
- 28: <advmanner> Advérbio: Modo
- 29: <advnonf> Advérbio: Não fatuais
- 30: <advnao> Advérbio: 'Não'

- 31: <advdown> Advérbio: Suavizadores
- 32: <advtime> Advérbio: Tempo
- 33: <advall> Advérbio: Todos
- 34: <artdef> Artigo: Definidos
- 35: <artindef> Artigo: Indefinidos
- 36: <cjadd> Conjunção: Coordenada (aditivas)
- 37: <cjadv> Conjunção: Coordenada (adversativas)
- 38: <cjcnci> Conjunção: Coordenada (conclusivas)
- 39: <cjcoorphr> Conjunção: Coordenada (frasais)
- 40: <cjcoorcls> Conjunção: Coordenada (oracionais)
- 41: <cjou> Conjunção: Coordenada (ou)
- 42: <cjcoor> Conjunção: Coordenada (todas)
- 43: <clauselgth> Contagens de palavras: Extensão média de oração
- 44: <wl> Contagens de palavras: Extensão média de palavra
- 45: <wrcount> Contagens de palavras: Quantidade de palavras
- 46: <ttr> Contagens de palavras: Razão forma-ocorrência
- 47: <qsqu> Interrogativa: Com advérbio interrogativo
- 48: <qsttag> Interrogativa: Questões 'tag'
- 49: <qsyn> Interrogativa: Sem advérbio interrogativo
- 50: <mdconseguir> Modal: Conseguir
- 51: <mddever> Modal: Dever
- 52: <mdhaver> Modal: Haver que/de
- 53: <mdparecer> Modal: Parecer
- 54: <mdpoder> Modal: Poder
- 55: <mdprecisar> Modal: Precisar
- 56: <mdter> Modal: Ter que/de
- 57: <mdall> Modal: Todos

- 58: <mdoblig> Modal: Verbos de obrigação
- 59: <cjcaus> Oração: Coordenada (causal)
- 60: <cjcncsv> Oração: Coordenada (concessiva)
- 61: <cjcond> Oração: Coordenada (condicional)
- 62: <cjcnfm> Oração: Coordenada (conformativa)
- 63: <cjfinal> Oração: Coordenada (final)
- 64: <cjprop> Oração: Coordenada (proporcional)
- 65: <cjtemp> Oração: Coordenada (temporal)
- 66: <cjsub> Oração: Coordenada (todas)
- 67: <vbproghr> Oração: Oração progressiva reduzida
- 68: <clinfadj> Oração: Reduzida de infinitivo controlada por adjetivo
- 69: <adjattiinf> Oração: Reduzida de infinitivo controlada por adjetivo atitudinal (posicionamento)
- 70: <clinfadjaff> Oração: Reduzida de infinitivo controlada por adjetivo de afeição
- 71: <clinfadjeval> Oração: Reduzida de infinitivo controlada por adjetivo de avaliação
- 72: <clinfadjcert> Oração: Reduzida de infinitivo controlada por adjetivo de certeza
- 73: <clinfadjease> Oração: Reduzida de infinitivo controlada por adjetivo de facilidade ou dificuldade
- 74: <adjliklinf> Oração: Reduzida de infinitivo controlada por adjetivo de probabilidade (posicionamento)
- 75: <clinfadjwill> Oração: Reduzida de infinitivo controlada por adjetivo de volição
- 76: <adjfactinf> Oração: Reduzida de infinitivo controlada por adjetivo factivo (posicionamento)
- 77: <clinfprp> Oração: Reduzida de infinitivo controlada por preposição
- 78: <nattitinf> Oração: Reduzida de infinitivo controlada por substantivo atitudinal (posicionamento)
- 79: <nlikhinf> Oração: Reduzida de infinitivo controlada por substantivo de probabilidade (posicionamento)
- 80: <vbspchinf> Oração: Reduzida de infinitivo controlada por substantivo dicendi (posicionamento)
- 81: <nfactlinf> Oração: Reduzida de infinitivo controlada por substantivo factual (posicionamento)
- 82: <nnonfcinf> Oração: Reduzida de infinitivo controlada por substantivo não-factual

(posicionamento)

83: <vbcausque> Oração: Reduzida de infinitivo controlada por verbo causativo (posicionamento)

84: <vbcogninf> Oração: Reduzida de infinitivo controlada por verbo de cognição (posicionamento)

85: <vbdesrinf> Oração: Reduzida de infinitivo controlada por verbo de desejo (posicionamento)

86: <vbprobinf> Oração: Reduzida de infinitivo controlada por verbo de probabilidade (posicionamento)

87: <clqueeadj> Oração: Subordinada com 'que' controlada por adjetivo

88: <adjque> Oração: Subordinada com 'que' controlada por adjetivo (posicionamento)

89: <adjattique> Oração: Subordinada com 'que' controlada por adjetivo atitudinal (posicionamento)

90: <clqueadjeval> Oração: Subordinada com 'que' controlada por adjetivo de avaliação

91: <clqueadjcert> Oração: Subordinada com 'que' controlada por adjetivo de certeza

92: <clqueadjease> Oração: Subordinada com 'que' controlada por adjetivo de facilidade ou dificuldade

93: <adjliklque> Oração: Subordinada com 'que' controlada por adjetivo de probabilidade (posicionamento)

94: <adjfactque> Oração: Subordinada com 'que' controlada por adjetivo factivo (posicionamento)

95: <clqueeadv> Oração: Subordinada com 'que' controlada por advérbio

96: <clqueeprp> Oração: Subordinada com 'que' controlada por preposição

97: <nounque> Oração: Subordinada com 'que' controlada por substantivo

98: <vbcausinf> Oração: Subordinada com 'que' controlada por substantivo causativo (posicionamento)

99: <vbcognque> Oração: Subordinada com 'que' controlada por substantivo cognitivo (posicionamento)

100: <nattitque> Oração: Subordinada com 'que' controlada por substantivo de atitude (posicionamento)

101: <vbdesrque> Oração: Subordinada com 'que' controlada por substantivo de desejo (posicionamento)

102: <nliklhque> Oração: Subordinada com 'que' controlada por substantivo de probabilidade (posicionamento)

103: <nfactlque> Oração: Subordinada com 'que' controlada por substantivo factual (posicionamento)

- 104: <nnonfcque> Oração: Subordinada com 'que' controlada por substantivo não-factual (posicionamento)
- 105: <clqueevb> Oração: Subordinada com 'que' controlada por verbo
- 106: <vbprobque> Oração: Subordinada com 'que' controlada por verbo de probabilidade (posicionamento)
- 107: <vbस्पchque> Oração: Subordinada com 'que' controlada por verbo dicendi (posicionamento)
- 108: <vbqueindic> Oração: Subordinada com 'que' controlada por verbo no modo indicativo
- 109: <vbquesubjc> Oração: Subordinada com 'que' controlada por verbo no modo subjuntivo
- 110: <adjqueinfcl> Oração: Subordinada com 'que' ou reduzida de infinitivo controlada por adjetivo (posicionamento)
- 111: <nqueinfcl> Oração: Subordinada com 'que' ou reduzida de infinitivo controlada por substantivo (posicionamento)
- 112: <vbqueinfcl> Oração: Subordinada com 'que' ou reduzida de infinitivo controlada por verbo
- 113: <vbCU> Oração: Subordinada com elemento 'qu' controlada por verbo
- 114: <cjsubother> Oração: Subordinada, exceto causal, concessiva ou condicional
- 115: <clpostnom> Outras: Oração reduzida de particípio
- 116: <clpasspor> Outras: Voz passiva com agente
- 117: <clsepass> Outras: Voz passiva pronominal
- 118: <clpassless> Outras: Voz passiva sem agente
- 119: <contrac> Outros: Contrações
- 120: <focusmkr> Outros: Marcador de foco
- 121: <discmrkr> Outros: Marcadores discursivos
- 122: <subjdrop> Outros: Omissão de sujeito
- 123: <prpall> Preposição: Todas
- 124: <prndem> Pronome: Demonstrativos
- 125: <prnnomsubj> Pronome: Nominal em posição de sujeito
- 126: <prn1obl> Pronome: Oblíquo de primeira pessoa
- 127: <prn2obl> Pronome: Oblíquo de segunda pessoa
- 128: <prn3obl> Pronome: Oblíquo de terceira pessoa

- 129: <prnposs> Pronome: Possessivos
- 130: <prn1plusubj> Pronome: Primeira pessoa do plural, em posição de sujeito
- 131: <prn1sngsubj> Pronome: Primeira pessoa do singular, em posição de sujeito
- 132: <prnrelprep> Pronome: Pronome relativo precedido de preposição
- 133: <prnqualcujo> Pronome: 'Qual' ou 'cujo' como pronome relativo
- 134: <prnqtf> Pronome: Quantificadores
- 135: <prnque> Pronome: 'Que' como pronome relativo
- 136: <objprnrare> Pronome: Raro em posição de objeto
- 137: <prn2plusubj> Pronome: Segunda pessoa do plural, em posição de sujeito
- 138: <prn2sngsubj> Pronome: Segunda pessoa do singular, em posição de sujeito
- 139: <prn3plusubj> Pronome: Terceira pessoa do plural, em posição de sujeito
- 140: <prn3sngsubj> Pronome: Terceira pessoa do singular, em posição de sujeito
- 141: <nabst> Substantivo: Abstratos
- 142: <nanim> Substantivo: Animados
- 143: <ncomp> Substantivo: Compostos
- 144: <nconc> Substantivo: Concretos
- 145: <ncogn> Substantivo: De cognição
- 146: <nplac> Substantivo: De lugar
- 147: <nqtty> Substantivo: De quantidade
- 148: <clnsbjc> Substantivo: Em posição de sujeito
- 149: <ngrpi> Substantivo: Institucionais
- 150: <nominlzsubj> Substantivo: Nominalização em posição de sujeito
- 151: <nominlz> Substantivo: Nominalizações
- 152: <nprop> Substantivo: Próprios
- 153: <ntech> Substantivo: Técnicos
- 154: <nall> Substantivo: Todos, exceto nominalizações
- 155: <vbpfaspct> Verbo: Aspecto perfeito

- 156: <vbaspct> Verbo: Aspectuais
- 157: <advsplit> Verbo: Auxiliares com clivagem
- 158: <vbact> Verbo: De ação
- 159: <vbcomm> Verbo: De comunicação
- 160: <vbexist> Verbo: De existência ou relação
- 161: <vbfacil> Verbo: De facilitação
- 162: <vbocc> Verbo: De ocorrência
- 163: <vbprog> Verbo: Forma composta contínua
- 164: <vbproginf> Verbo: Forma composta contínua precedida de infinitivo
- 165: <vbfutpret> Verbo: Futuro do passado
- 166: <vbfutpres> Verbo: Futuro do presente
- 167: <vbsubfut> Verbo: Futuro do subjuntivo
- 168: <vbfutir> Verbo: Futuro perifrástico com 'ir'
- 169: <vbgerall> Verbo: Gerúndio
- 170: <vbimp> Verbo: Imperativo
- 171: <vbinf> Verbo: Infinitivo
- 172: <vinfpers> Verbo: Infinitivo pessoal
- 173: <vbplupf> Verbo: Mais que perfeito
- 174: <vbment> Verbo: Mentais
- 175: <vbindic> Verbo: Modo indicativo
- 176: <vbpastprt> Verbo: Particípio passado
- 177: <vbsua> Verbo: Persuasivos
- 178: <vbpres> Verbo: Presente do indicativo
- 179: <vbsubpres> Verbo: Presente do subjuntivo
- 180: <vbpast> Verbo: Pretérito do indicativo
- 181: <vbsubpast> Verbo: Pretérito do subjuntivo
- 182: <vbimperf> Verbo: Pretérito imperfeito

- 183: <vb1> Verbo: Primeira pessoa
- 184: <vbpriv> Verbo: Privados
- 185: <vbpubl> Verbo: Públicos
- 186: <vb2> Verbo: Segunda pessoa
- 187: <vbserestar> Verbo: 'Ser' ou 'estar'
- 188: <vb3> Verbo: Terceira pessoa
- 189: <vball> Verbo: Todos
- 190: <vbaux> Verbo: Verbo auxiliar

8.2. Excerto do *script* TagCounter

```
conjunctions () {  
  
filestopprocess  
  
echo "-- conjunctions --"  
  
for filelist in `ls textfiles??`  
do  
    echo "----- DOING $filelist -----"  
    while read filein fileout outputdir  
    do  
        echo "----- doing $filein -----"  
        grep -H 'postag="KC"' $filein >  
"$outputdir"/$fileout.cj.conjunction_coordinating.cjcoor.instances  
        pcregrep -H -M  
'form="e".*\n.*postag="V"|form="e".*\n.*postag="ADV"|form="ou".*\n.*postag="V"|form="ou".*\n.*p  
ostag="ADV"|form="e".*\n.*postag="SPEC"|form="ou".*\n.*postag="SPEC"|form="nem".*\n.*posta  
g="V"|form="E".*\n.*postag="KC"|form="Ou".*\n.*postag="KC"|form="Nem".*\n.*postag="KC"|form="porém"|  
form="contudo"|form="entretanto"|form="senão"|form="pois"|form="portanto"|form="por_isso"  
$filein > "$outputdir"/$fileout.cj.conjunction_coordinating_clausal.cjcoorcls.instances  
        pcregrep -H -M  
'postag="N".*\n.*form="e".*\n.*postag="KC".*\n.*postag="N"|postag="N".*\n.*form="ou".*\n.*postag="KC"  
.*\n.*postag="N"|postag="ADJ".*\n.*form="e".*\n.*postag="KC".*\n.*postag="ADJ"|postag="ADJ".*\n.*  
form="ou".*\n.*postag="KC".*\n.*postag="ADJ"|postag="N".*\n.*form="e".*\n.*postag="KC".*\n.*postag="ADJ"|postag="N".*\n.*form="ou".*\n.*postag="KC".*\n.*postag="ADJ"|  
postag="ADJ".*\n.*form="e".*\n.*postag="KC".*\n.*postag="N"|postag="ADJ".*\n.*form="ou".*\n.*postag=  
"KC".*\n.*postag="N"' $filein >  
"$outputdir"/$fileout.cj.conjunction_coordinating_phrasal.cjcoorphr.instances  
        pcregrep -H -M '.*base="mas"|base="também"' $filein >  
"$outputdir"/$fileout.cj.conjunction_coordinating_additive.cjadd.instances  
        pcregrep -H 'base="e" postag="KC"|base="nem" postag="KC"' $filein >>  
"$outputdir"/$fileout.cj.conjunction_coordinating_additive.cjadd.instances  
        pcregrep -H  
'form="mas"|form="porém"|form="todavia"|form="entretanto"|form="no_entanto"|form="senão"|for
```

```
m="não_obstante"|form="contudo" $filein >
"$outdir/$fileout.cj.conjunction_coordinating_adversative.cjadv.instances
  pcregrep -H 'base="ou" postag="KC"' $filein >
"$outdir/$fileout.cj.conjunction_coordinating_ou.cjou.instances
  pcregrep -H
'base="portanto"|base="pois"|base="então"|base="por_isso"|base="por_consequente" $filein >
"$outdir/$fileout.cj.conjunction_coordinating_conclusive.cjcncl.instances
```

8.3. Excerto dos parâmetros de busca de verbos do PalavrasCounter

POS tag group name = vb
POS tag group label = Verbs

POS tag type name = verbs_all
POS tag type label = Verbs All

POS tag name = vball

POS search string = postag="V"
POS precondition search string =
POS condition search string = postag="V"
POS postcondition search string =
POS negation search string =

POS tag type name = ser_estar_main
POS tag type label = Ser Estar Main

POS tag name = vbserestar

POS search string = base="ser"|base="estar"
POS precondition search string =
POS condition search string = base="estar"|base="ser".*extra="% mv%"
POS postcondition search string =
POS negation search string =

POS tag type name = present
POS tag type label = Present

POS tag name = vbpres

POS search string = morf="PR.*IND
POS precondition search string =
POS condition search string = morf="PR%IND%"
POS postcondition search string =
POS negation search string =

POS tag type name = past
POS tag type label = Past

POS tag name = vbpast

POS search string = morf="PS.*IND

POS precondition search string =
POS condition search string = morf="PS%IND%"
POS postcondition search string =
POS negation search string =

POS tag type name = pluperfect
POS tag type label = Pluperfect

POS tag name = vbplupf

POS search string = morf="MQP
POS precondition search string =
POS condition search string = morf="MQP%"
POS postcondition search string =
POS negation search string =

POS tag type name = imperfect
POS tag type label = Imperfect

POS tag name = vbimpf

POS search string = morf="IMPF
POS precondition search string =
POS condition search string = morf="IMPF%"
POS postcondition search string =
POS negation search string =

POS tag type name = future
POS tag type label = Future

POS tag name = vbfutpres

POS search string = morf="FUT.*IND
POS precondition search string =
POS condition search string = morf="FUT%IND%"
POS postcondition search string =
POS negation search string =

POS tag type name = future_ir
POS tag type label = Future Ir

POS tag name = vbfutir

POS search string = .*base="ir".*\n.*morf="INF"
POS precondition search string =
POS condition search string = base="ir"
POS postcondition search string = morf="INF"
POS negation search string =